

# 车联网与移动边缘计算 (MEC)

学号：2120250723

姓名：于成俊

## 一、论文一

### (1) 论文相关信息

- 标题：Multi-UAV-Assisted MEC in Internet of Vehicles With Combined Multi-Modal Semantic Communication Under Jamming Attacks

- 作者：Shuai Liu, Helin Yang, Mengting Zheng, Liang Xiao

- 出处：IEEE TRANSACTIONS ON MOBILE COMPUTING (TMC)

- 日期：2025年8月

- 英文摘要：

Semantic communication technology, which transmits only relevant semantic information, can significantly conserve communication resources and reduce service time. This technology is particularly promising for unpiloted aerial vehicle (UAV)-assisted mobile edge computing (MEC) in the internet of vehicles (IoV). However, integrating semantic communication with UAV-assisted vehicle MEC is susceptible to malicious jamming. This paper introduces a reliable communication method that combines multi-modal semantic communication with UAV-assisted vehicle MEC to minimize delays in communication and computation while maintaining semantic accuracy during jamming attacks. Our approach optimizes UAV trajectories, user associations, and channel selections, enabling the UAV to select optimal positions when associating with different modal users and reducing the impact of jammers during multi-modal task reception. Due to the non-convex nature of the optimization problem and the highly dynamic environment, we employ the semantic communication combined with the multi-agent twin delayed deep deterministic policy gradient (SC-MA-TD3) approach, a multi-agent deep reinforcement learning (DRL) strategy that fosters UAV cooperation for efficient resource allocation. Simulation results show that our approach outperforms existing approaches in reducing delays and enhancing semantic accuracy.

- 中文摘要：

语义通信技术只传输与任务相关的语义信息，从而能够显著节省通信资源并减少服务时延。该技术在无人机（UAV）辅助的车联网（IoV）中的移动边缘计算（MEC）中具有广阔的应用前景。然而，将语义通信与无人机辅助的车辆移动边缘计算相结合时，系统容易受到恶意干扰攻击的影响。为此，本文提出了一种可靠的通信方法，将多模态语义通信与无人机辅助的车辆移动边缘计算相融合，在遭受干扰攻击时能够在保证语义准确性的同时最小化通信与计算的延迟。我们的方法通过联合优化无人机轨迹、用户关联关系和信道选择，使无人机在与不同模态用户交互时能够选择最优位置，从而在多模态任务接收过程中降低干扰的影响。由于该优化问题具有非凸性且环境高度动态化，我们采用了一种结合语义通信的多智能体双延迟深度确定性策略梯度（SC-MA-TD3）方法，这是一种多智能体深度强化学习（DRL）策略，用于促进无人机之间的协同，从而实现高效的资源分配。仿真结果表明，所提方法在降低延迟和提高语义准确性方面均优于现有方法。

- 英文关键字：

Multi-modal semantic communication, antijamming, UAV-assisted MEC, deep reinforcement learning, Internet of vehicles.

- 中文关键字：多模态语义通信，抗干扰，无人机辅助的移动边缘计算，深度强化学习，车联网。

## (2) 论文相关分析

### 1.研究背景

在车联网中，车辆与基础设施（如RSU）之间需要频繁交换大量数据（如图像、文本、交通信息等），传统通信方式面临以下挑战：

- **频谱资源紧张**：传统通信传输全部数据，效率低；
- **通信链路不稳定**：城市环境中存在大量NLoS（非视距）链路；
- **易受干扰攻击**：尤其在无人机辅助通信中，LoS链路更易被恶意干扰；
- **计算资源有限**：无人机虽具备边缘计算能力，但资源受限；
- **多模态信息融合难**：图像、文本等多种语义信息需协同处理。

本篇论文所研究的是：在车联网中，如何在受到无线干扰攻击的情况下，实现高效、低时延且高语义准确度的多模态信息传输与计算。

### 2.核心创新与贡献

- **首次提出多模态语义通信 + UAV辅助MEC + 抗干扰DRL的联合框架**：将图像与文本语义信息融合为“多模态任务”，通过无人机进行统一接收与处理，然后利用语义通信（DeepSC-VQA模型）只传输“有用信息”，显著节省频谱资源，并在无人机端进行边缘计算，实现低延迟处理。在干扰攻击环境下，通过深度强化学习动态调整无人机轨迹、用户关联和信道选择，保障通信可靠性。
- **设计了SC-MA-TD3算法来解决多UAV协同优化问题**：它通过使用双Q网络结构来缓解过估计问题，提升稳定性；并让多智能体协同工作，以此适应复杂动态环境；还设置了语义感知奖励机制，来联合优化通信延迟、计算延迟与语义准确度；它还具备在线学习能力，可实时适应干扰变化。

注：SC-MA-TD3算法为Semantic Communication aided Multi-Agent Twin Delayed Deep Deterministic Policy Gradient

- **构建了真实感强的系统模型**，主要包括以下几个模型：

- **信道模型**：考虑LoS/NLoS概率、干扰功率、瑞利衰落；
- **任务模型**：图像采集车辆与文本RSU分别上传语义任务；
- **语义通信模型**：定义语义速率、语义准确度等指标；
- **延迟模型**：综合考虑通信延迟与计算延迟；
- **干扰模型**：模拟动态干扰源对多信道的影响。

### 3.实验

本篇文章与SC-MA-DDPG、SC-D4N、SC-MA-TD3-F、N-SC-MA-TD3四种方法在通信与计算延迟、语义准确度、语义速率、鲁棒性四个方面进行了对比，本文方法SC-MA-TD3都是表现最好的，结果如下：

性能指标	SC-MA-TD3 表现	提升幅度
通信与计算延迟	最低 (~365ms)	降低 ≥29.07%
语义准确度	最高 (~10.1%)	提升 ≥4.33%
语义速率	最高	提升 ≥2.67%
鲁棒性	最强	

## (3) 总结和展望

### 1. 总结

这篇论文提出了一种面向车联网的多无人机辅助移动边缘计算（MEC）方案，将多模态语义通信与深度强化学习（SC-MA-TD3）相结合，以在存在干扰攻击的复杂动态环境中实现最优的通信与计算资源调度。该方法通过联合优化无人机的轨迹、用户关联与信道选择，显著降低了系统的通信与计算时延，并提升了语义传输的准确性。仿真结果表明，所提方案在不同干扰强度和用户规模下均优于传统方法，展现出较强的鲁棒性与自适应能力。

整体来说，该篇论文提出的方法将传统V2X通信拓展为语义级别的信息交互，实现了车载传感数据与道路环境语义融合，显著提升了车联网通信效率与智能化水平，又通过无人机实现“空-地协同边缘计算”，动态优化任务卸载策略与计算资源分配，显著降低了车载终端的计算压力。

### 2. 展望

尽管本文已构建一个较为完整的系统框架，但仍存在以下值得深入探索的方向：

- **多模态语义融合机制深化**：未来可探索语音、雷达、激光雷达（LiDAR）等更多模态的语义通信。
- **干扰建模更智能化**：当前干扰源为单一、移动式干扰，未来可引入智能干扰源（如基于AI的干扰策略）。未来还可以研究一下**博弈论或对抗学习**框架下的干扰与抗干扰博弈。
- **UAV群体智能与自组织网络**：探索UAV自组网（FANET）架构下的协同通信与计算，或者尝试引入联邦学习或群体智能算法实现分布式学习与协同决策。
- **能耗与安全性联合优化**：在UAV能量受限条件下，联合优化能耗、延迟、安全，引入物理层安全、语义加密等机制，提升系统安全性。

## 二、论文二

### (1) 论文相关信息

- 标题：MMTO: Multi-Vehicle Multi-Hop Task Offloading in MEC-Enabled Vehicular Networks
- 作者：Wenjie Huang, Zhiwei Zhao, Geyong Min, Yang Wang, Zheng Chang
- 出处：IEEE TRANSACTIONS ON MOBILE COMPUTING (TMC)
- 日期：2025年10月
- 英文摘要：

Mobile Edge Computing (MEC)-enabled vehicular networks have emerged as a promising approach to enhancing the performance and efficiency of the Internet-of-Vehicles (IoV) applications. By leveraging some vehicles to act as transmission relays, multi-hop task offloading addresses the problem of intermittent connectivity between vehicles and edge servers to cope with the issues of network congestion or obstacles. However, two critical issues, i.e., uncooperative behaviors of selfish vehicles and network resource dynamics, resulting from multi-vehicle concurrent offloading are not fully considered in the existing work. To fill this gap, this paper proposes a novel and efficient task offloading scheme, namely MMTO, that exploits the multi-hop computational resources to maximize the system-wide profit, and supports incentive compatibility of vehicular users and concurrent offloading. Specifically, an iterative hierarchical estimation algorithm is designed to estimate the offloading delay and energy cost in order to iteratively optimize the offloading decisions. An energy-efficient routing approach is then proposed to schedule the transmission paths for the offloading vehicles. Furthermore, an effective reward-driven auction-based incentive mechanism is designed for incentivizing relayers and calculators to engage in collaboration. Both simulation and field experiments are conducted; extensive results demonstrate that MMTO outperforms the state-of-the-art approaches in terms of the system-wide profit improvement and overall task delay reduction.

- 中文摘要:

支持移动边缘计算 (MEC) 的车载网络已成为提升车联网 (IoV) 应用性能与效率的有前景的解决方案。通过让部分车辆充当传输中继节点, 多跳任务卸载能够缓解车辆与边缘服务器之间间歇性连接的问题, 从而应对网络拥塞或障碍带来的影响。然而, 现有研究往往未充分考虑两个关键问题: **自私车辆的不合作行为以及多车辆并发卸载导致的网络资源动态性。**

为弥补这一研究空白, 本文提出了一种新颖且高效的任务卸载方案——MMTO (Multi-hop Multi-vehicle Task Offloading)。该方案充分利用多跳计算资源以最大化系统整体收益, 同时支持车载用户的激励相容性和并发卸载。具体而言, 本文设计了一种**迭代分层估计算法**, 用于估计卸载延迟与能耗成本, 从而迭代优化卸载决策; 随后, 提出了一种**能量高效的路由调度方法**, 以为卸载车辆规划合适的传输路径。此外, 本文还设计了一种**基于奖励驱动的拍卖型激励机制**, 用于激励中继车辆和计算车辆参与协同合作。

通过仿真与实地实验的验证, 结果表明, MMTO在提升系统总体收益和降低任务整体延迟方面, 均优于当前的先进方法。

- 英文关键字:

Mobile edge computing (MEC), multi-hop task offloading, Internet-of-Vehicles (IoV), incentive mechanism, routing.

- 中文关键字:

移动边缘计算、多跳任务卸载、车联网、激励机制、路由。

## (2) 论文相关分析

### 1. 研究背景

随着智能网联汽车和5G/6G通信技术的快速发展, 车联网 (Internet of Vehicles, IoV) 正从传统的信息交互向智能计算协同演进。车辆终端产生的计算任务 (如图像识别、路径规划、环境感知) 对实时性和计算能力提出了极高要求。然而, 车辆本地计算资源有限, 难以满足这些需求。移动边缘计算 (Mobile Edge Computing, MEC) 通过将计算能力下沉到网络边缘 (如基站、路侧单元), 为车辆提供低延迟、高带宽的计算服务, 成为支撑车联网智能应用的关键技术。

尽管MEC为车联网提供了新的计算范式, 但在实际部署中仍面临以下挑战:

- **网络连接不稳定**: 城市环境中存在信号遮挡、基站覆盖盲区，导致车辆无法直接连接边缘服务器。
- **车辆自私行为**: 车辆作为中继或计算节点时，可能不愿无偿协助他人，缺乏有效激励机制。
- **多车并发卸载冲突**: 多辆车同时请求卸载任务，会造成通信与计算资源竞争，影响系统性能。
- **路径选择与资源调度耦合复杂**: 多跳卸载中，路径选择、任务分配与激励策略相互影响，建模与求解难度大。

现有研究大多聚焦于单跳卸载（V2I 或 V2V），忽略了多跳中继卸载的潜力，也未能充分考虑车辆自私行为与多车并发卸载带来的资源竞争问题。

因此，本文提出MMTO（Multi-Vehicle Multi-Hop Task Offloading）机制来解决上述问题。

## 2.核心创新与贡献

- **首次系统性地考虑多车并发卸载与多跳协同**: 传统研究多聚焦于单跳卸载（V2I或V2V），即车辆只能将任务卸载到通信范围内的基站或邻近车辆，忽略了障碍物遮挡、网络拥塞等导致的连接中断问题。而本篇文章的方法**MMTO**提出多跳任务卸载机制，允许车辆通过其他车辆作为中继节点，将任务转发至更远的边缘服务器或空闲车辆，扩大了边缘服务的覆盖范围，提升了网络资源利用率。
- **引入激励机制，解决车辆“自私”问题**: 实际中，车辆作为中继或计算节点时可能不愿无偿协助，导致协作失败。本文设计了基于拍卖的奖励驱动激励机制，通过出价竞标的方式，激励车辆参与中继与计算任务，保证任务卸载过程的可持续性和协作性。
- **联合优化卸载决策、路径选择与激励策略**: 将卸载决策、路径调度与出价策略三者联合建模为一个系统效用最大化问题，突破了传统研究中将它们割裂处理的局限；并提出分层估计模型 + 贪婪路由算法 + 凸优化求解出价策略的三段式求解框架，兼顾系统性能与计算效率。
- **考虑了车辆移动性对通信链路的影响**: 引入链路生命周期模型，确保任务传输在通信链路有效期内完成，避免因车辆移动导致的中断。路由算法中还融合了移动性感知机制，动态调整路径选择，提升传输稳定性。

## 3.仿真实验

- 本篇文章与O-V2I、O-V2V、Non-IM三种方法在以下三个指标进行了对比：
  - **系统总效用**: 所有车辆任务完成的总收益减去能耗成本
  - **平均任务延迟**: 所有任务从发起到完成的平均时间
  - **卸载比例**: 实际卸载任务数 / 总任务数
- 实验设置如下：

参数	设置
车辆总数	120辆（100辆活跃任务车辆，20辆候选中继车辆）
基站数量	3个
任务数据量	100–500 KB
任务截止时间	1–1.5 秒
通信带宽	2 MHz (V2I 与 V2V)
车辆计算能力	1–2 GHz

参数	设置
基站/候选车辆计算能力	30–50 GHz / 10–15 GHz
网络拓扑	基于真实高架道路车辆轨迹数据 (Ubiquitous Traffic Eyes)

- 实验结果如下：

对比维度	MMTO表现
系统总效用	比O-V2I提升约13.94%，比O-V2V提升约8.63%，优于Non-IM
平均延迟	比O-V2I降低约22.93%，比O-V2V降低约15.31%
卸载比例	比O-V2I提升超300%，比O-V2V提升约140%，显著更高
带宽变化适应性	在不同信道带宽下，MMTO始终优于其他算法

## 4. 实地实验

- 实验平台如下：

项目	配置
实验场地	室内 2m × 2m 区域
车辆节点	9辆小型智能车，每辆搭载 Jetson Nano
边缘服务器	一台Win10 PC，配备RTX 3060 GPU
任务类型	图像识别 (YOLOv5)
通信方式	模拟V2V/V2I通信，传输速率根据距离模型计算
网络拓扑	构建3跳多跳网络，模拟真实多跳卸载路径

- 实验结果：

- MMTO相比本地计算 (LC)，任务平均延迟降低约 48.3%；
- 在多跳路径存在的情况下，MMTO能有效利用中继车辆与边缘服务器协同处理任务；
- 实验验证了MMTO在小规模真实环境下的可行性与有效性。

## (3) 总结和展望

### 1. 总结

MMTO方案在多车多跳任务卸载场景下，首次系统性地融合了激励机制、并发卸载建模与路径优化，有效解决了车辆自私行为与资源动态变化带来的挑战。通过仿真与实地实验证，其在系统收益、任务延迟、卸载成功率等方面均优于传统单跳卸载方案，具备良好的应用前景。

### 2. 展望

未来可进行以下几个方面的研究：

- 引入RIS (可重构智能表面) 技术：**未来可结合RIS优化信号覆盖与传输质量，提升复杂城市环境下的卸载性能。

- **支持异构任务与服务质量 (QoS) 保障:** 当前模型假设任务同质化，后续可考虑任务类型、优先级、QoS需求差异化。
- **强化学习与智能决策:** 可引入深度强化学习 (DRL) 实现更智能的卸载决策与路径选择，适应更复杂的动态环境。
- **隐私与安全机制:** 虽然论文提到可集成加密与认证机制，但未深入探讨，未来可研究隐私保护下的激励机制与安全卸载路径选择。

## 三、论文三

### (1) 论文相关信息

- 标题： Mobility-Aware Seamless Service Migration and Resource Allocation in Multi-Edge IoV Systems

- 作者： Zheyi Chen, Sijin Huang, Geyong Min, Zhaolong Ning, Jie Li, Yan Zhang

- 出处： IEEE TRANSACTIONS ON MOBILE COMPUTING (TMC)

- 日期： 2025年7月

- 英文摘要：

Mobile Edge Computing (MEC) offers low-latency and high-bandwidth support for Internet-of-Vehicles (IoV) applications. However, due to high vehicle mobility and finite communication coverage of base stations, it is hard to maintain uninterrupted and high-quality services without proper service migration among MEC servers. Existing solutions commonly rely on prior knowledge and rarely consider efficient resource allocation during the service migration process, making it hard to reach optimal performance in dynamic IoV environments. To address these important challenges, we propose SR-CL, a novel mobility-aware seamless Service migration and Resource allocation framework via Convex-optimization-enabled deep reinforcement Learning in multi-edge IoV systems. First, we decouple the Mixed Integer Nonlinear Programming (MINLP) problem of service migration and resource allocation into two sub-problems. Next, we design a new actor-critic-based asynchronous-update deep reinforcement learning method to handle service migration, where the delayed update actor makes migration decisions and the one-step-update critic evaluates the decisions to guide the policy update. Notably, we theoretically derive the optimal resource allocation with convex optimization for each MEC server, thereby further improving system performance. Using the real-world datasets of vehicle trajectories and testbed, extensive experiments are conducted to verify the effectiveness of the proposed SR-CL. Compared to benchmark methods, the SR-CL achieves superior convergence and delay performance under various scenarios.

- 中文摘要：

移动边缘计算 (MEC) 为车联网 (IoV) 应用提供了低时延和高带宽的支持。然而，由于车辆具有高机动性，且基站的通信覆盖范围有限，如果缺乏合理的服务迁移机制，则难以在车载移动环境中维持连续且高质量的服务。现有解决方案通常依赖先验知识，且很少在服务迁移过程中考虑高效的资源分配，这使得在动态的车联网环境中难以获得最优性能。

为解决这些关键问题，本文提出了一种新颖的、面向移动性的无缝服务迁移与资源分配框架——SR-CL (Seamless service migration and Resource allocation via Convex-optimization-enabled deep reinforcement Learning)，该框架结合了凸优化理论与深度强化学习，专为多边缘IoV系统设计。

首先，我们将服务迁移与资源分配的混合整数非线性规划问题（MINLP）分解为两个子问题；随后，设计了一种新的基于actor-critic（行动者-评论者）结构的异步更新深度强化学习方法来处理服务迁移问题。其中，延迟更新的actor负责做出迁移决策，而一步更新的critic负责评估这些决策并指导策略更新。值得注意的是，我们还基于凸优化理论，为每个MEC服务器推导出最优的资源分配策略，从而进一步提升系统整体性能。

基于真实的车辆轨迹数据集和测试平台进行的大量实验表明，SR-CL在多种场景下均表现出更快的收敛速度和更低的时延，显著优于现有基线方法。

- 英文关键字：

Mobile edge computing (MEC), Internet-of Vehicles (IoV), service migration, deep reinforcement learning, convex optimization.

- 中文关键字：

移动边缘计算、车联网、服务迁移、深度强化学习、凸优化。

## (2) 论文相关分析

### 1. 研究背景

随着5G/6G和边缘计算（MEC）技术的发展，车联网（IoV）正从传统的信息交互向智能计算协同演进。车辆终端产生的计算任务（如图像识别、路径规划、环境感知）对低延迟、高可靠性的服务提出了极高要求。然而，车辆高速移动导致其频繁切换基站（BS），使得原本部署在某个边缘节点（MEC Server）上的服务实例可能脱离覆盖范围，造成：

- 服务中断；
- 通信延迟增加；
- 用户体验下降。

因此，服务迁移（Service Migration）成为保障服务质量（QoS）的关键手段。

由于车辆移动性高，导致服务实例很难动态跟随车辆迁移，从而会出现通信中断的情况。此外，MEC服务器计算资源有限，需要合理分配资源以降低任务处理延迟。而且，迁移与资源分配耦合复杂，二者相互影响，联合优化难度大，传统方法易陷入局部最优。再加上车辆轨迹、任务负载、网络拓扑等实时变化，方法还需具备自适应能力。基于此，本文提出了一种新颖的、面向移动性的无缝服务迁移与资源分配框架——SR-CL。

### 2. 核心创新与贡献

本文提出**SR-CL**框架，创新性地将服务迁移与资源分配联合建模为**MINLP问题**，目标是最小化系统总延迟（迁移+通信+计算）。然后利用Tammer分解法将原问题拆分为两个子问题：①服务迁移决策（DRL求解）；②资源分配（凸优化求解）。主要贡献和创新点如下：

- **迁移策略学习**：提出一种**改进的Actor-Critic DRL算法**，引入：
  - 延迟更新 Actor（稳定训练）；
  - 单步更新 Critic（快速收敛）；
  - 高斯噪声探索机制。
- **资源分配优化**：理论证明了资源分配子问题为凸问题，基于KKT条件推导出**闭式最优解**，无需迭代求解，极大提升效率。
- **系统实现**：提出完整的系统架构，支持在真实车辆轨迹数据与Simu5G平台上部署与验证。

### 3.实验

#### 1.仿真实验①

- 实验相关设置：
  - 数据集：意大利罗马市出租车轨迹数据（320辆车，30天）
  - 仿真区域：城市中心  $16 \text{ km}^2$ ，部署 16 个边缘节点
  - 任务设置：每辆车每时隙生成一个计算任务（数据量、计算密度随机）
  - 对比算法：AM、NM、GA、IDQN、JSR、DDPG 等
  - 评价指标：总延迟（迁移+通信+计算）、迁移频率、收敛速度、任务响应时间等
- 实验结果：
  - 总延迟：比 DDPG 降低 3.6%~5.5%，比 JSR 降低 9% 以上，显著优于其他方法
  - 迁移频率：迁移次数更少，策略更稳定
  - 收敛速度：训练过程更平稳，收敛更快，优于 IDQN 与 DDPG
  - 动态适应性：在任务量、网络拓扑、带宽、迁移延迟系数变化下均表现最优
  - 可扩展性：在 25 节点大规模网络下依然保持优越性能
  - 决策时间：虽略高于规则方法，但远低于 GA，具备实时性潜力

#### 2.仿真实验②

基于 **OMNeT++ + Simu5G** 构建了 5G 网络仿真平台，在仿真平台上模拟 10 辆车的移动与服务迁移过程。实测指标包括响应时间 (responseTime)、上行时延 (upLinkTime)，结果显示 SR-CL 在不同车速与位置下均优于传统策略 (SEGREGATION 与 FAIR)。

### (3) 总结和展望

#### 1.总结

本文提出的 SR-CL 框架是首个将深度强化学习与凸优化理论有机融合，用于解决多边缘车联网中服务迁移与资源分配联合优化问题的研究。通过问题解耦、算法创新、理论推导与系统验证，实现了更低的系统延迟、更高的迁移效率、更强的动态适应能力，以及更好的训练稳定性与可扩展性。

#### 2.展望

文章当前仅以延迟为目标，未来可以引入能耗优化目标，联合优化能耗与延迟，提升绿色计算能力。并且，文章目前的DRL代理是集中部署的，未来可以进行分布式部署，探索多智能体协同机制，提升系统可扩展性。此外，文章的实验目前仅使用罗马数据集，未来可扩展至更多城市与高速公路场景，验证模型泛化能力；还可以结合 5G 基站与车载终端，开展更大规模的实地测试，推动成果落地应用。

## 四、论文四

### (1) 论文相关信息

- 标题：Multi-Objective Decomposition Evolutionary DRL for UAV-Assisted MEC in Internet of Vehicles
- 作者：Lei Zhang, Can Tian, Tingting Liu, Xingwang Li, Shahid Mumtaz, Wali Ullah Khan
- 出处：IEEE TRANSACTIONS ON VEHICULAR TECHNOLOGY (TVT)

- 日期: 2025年8月

- 英文摘要:

Dynamic multi-objective optimization in Unmanned Aerial Vehicle (UAV)-assisted Mobile Edge Computing (MEC) for Internet of Vehicles (IoV) faces significant challenges, due to complex operational environments and conflicting objectives. While Deep Reinforcement Learning (DRL) enables real-time optimization, conventional weighted-sum approaches fail to balance these objectives effectively. To address this, we propose a Multi-Objective Decomposition Evolutionary DRL (MODE-DRL) framework, which include the following three innovative aspects. Firstly, a multi-objective optimization model is developed, aiming to minimize delay and energy consumption while maximizing the number of completed tasks, thus ensuring overall network performance. Secondly, a novel MODE strategy that dynamically associates weight vectors with learning agents to optimize policy distribution and enhance population diversity. Lastly, two integrated algorithms, called MODE with Proximal Policy Optimization (MODE-PPO) and MODE with Deep Deterministic Policy Gradient (MODE-DDPG), are developed to combine DRL's dynamic decision-making with MODE's global optimization capabilities, enabling agents to rapidly adapt strategies based on different weights. Experimental results demonstrate that the MODE-DRL achieves a 33.2% improvement in hypervolume, along with a 16.3% reduction in average delay, a 15.5% decrease in average energy consumption, and a 34.4% increase in average number of completed tasks. These results confirm that MODE-DRL exhibits significant advantages in both convergence and diversity, while enhancing overall network performance. This work provides a scalable paradigm for real-time multi-objective decision-making in UAV-assisted MEC for IoV systems.

- 中文摘要:

在无人机 (UAV) 辅助的车联网 (IoV) 移动边缘计算 (MEC) 中，动态多目标优化面临着严峻挑战，其原因在于复杂的运行环境以及目标之间的冲突。尽管深度强化学习 (DRL) 能够实现实时优化，但传统的加权求和方法 (weighted-sum approach) 难以在多个目标之间实现有效平衡。

为此，本文提出了一种多目标分解进化深度强化学习框架 (MODE-DRL, Multi-Objective Decomposition Evolutionary DRL)，该框架包含以下三项创新内容：

1. 多目标优化建模：构建了一个多目标优化模型，以同时最小化时延与能耗、并最大化已完成任务数量，从而保证车联网整体性能；
2. 新型MODE策略：设计了一种新颖的多目标分解进化策略，动态地将权重向量分配给学习智能体 (agents)，以优化策略分布并提升智能体种群的多样性；
3. 算法集成设计：进一步提出了两种融合算法——MODE-PPO (基于近端策略优化的 MODE) 和 MODE-DDPG (基于深度确定性策略梯度的 MODE)。这两种算法将DRL 的动态决策能力与 MODE 的全局优化能力相结合，使智能体能够根据不同的权重快速自适应策略更新。

实验结果表明，MODE-DRL框架在超体积指标 (hypervolume) 上提升了 33.2%，平均时延降低了 16.3%，平均能耗减少了 15.5%，平均完成任务数提高了 34.4%。这些结果证明，MODE-DRL在收敛性与多样性方面均表现出显著优势，同时有效提升了车联网的整体性能。

本研究为UAV辅助MEC的车联网系统中实时多目标决策提供了一种具有可扩展性的全新范式。

- 英文关键字:

Internet of Vehicles, Mobile Edge Computing, Deep Reinforcement Learning, Multi-objective Optimization.

- 中文关键字:

车联网、移动边缘计算、深度强化学习、多目标优化。

## (2) 论文相关分析

### 1. 研究背景

随着车联网（IoV）的快速发展，车辆对低延迟、高可靠的计算服务需求日益增长。移动边缘计算（MEC）通过将计算资源下沉到网络边缘，显著降低了任务处理延迟。然而，固定基站（BS）在城市交通拥堵、信号遮挡等场景下，存在覆盖不足、资源紧张等问题。

为此，无人机（UAV）作为空中移动边缘节点，被引入MEC系统中，具备：

- 快速部署、灵活机动；
- 动态调整飞行路径；
- 提供按需计算卸载服务。

但UAV辅助MEC也面临多目标冲突问题，如：

- 最小化任务延迟；
- 降低能耗；
- 最大化任务完成数量。

这些目标往往相互冲突，且环境动态变化，传统单目标优化或静态加权方法难以实时平衡。

基于此，本文提出了一种多目标分解进化深度强化学习框架来解决以上问题。

### 2. 核心创新与贡献

本文提出 MODE-DRL 框架：融合多目标分解与深度强化学习，主要有以下核心点

- 使用多目标建模，构建能同时考虑延迟、能耗、任务完成数量的动态多目标优化模型，适应城市拥堵场景。
- 提出双向匹配策略（BM），来解决传统MODE中权重向量与个体随机匹配导致的种群多样性下降问题。
- 提出了两种集成算法：
  - ① **MODE-PPO**：结合PPO的稳定策略更新；
  - ② **MODE-DDPG**：结合DDPG的连续动作空间优化能力。
- 采用向量奖励函数，保留多目标冲突信息，避免传统标量加权造成的信息损失。
- 加入了协同优化机制，让DRL负责生成高质量个体，让MODE负责全局演化与权重分配，实现探索与开发的平衡。

### 3. 实验

实验设置如下：

- 平台：Python + PyTorch，RTX 4060 GPU
- 场景：200m×200m 区域，40 个IoV用户随机分布
- UAV参数：最大速度 20m/s，飞行高度固定，任务队列容量 10
- 任务模型：任务大小 3MB，CPU周期 10<sup>9</sup>，到达服从伯努利分布
- 评价指标：HV（超体积）、AD（平均延迟）、AEC（平均能耗）、ANTC（平均完成任务数）

实验结果如下：

实验维度	MODE-DRL 表现
HV (超体积)	相比 MODE-SAC 和 MODE-TD3, 提升 33.2%, 表明 Pareto 解集更优
AD (平均延迟)	降低 16.3%
AEC (平均能耗)	降低 15.5%
ANTC (完成任务数)	提升 34.4%
不同权重轨迹分析	能根据权重动态调整飞行路径与任务策略, 验证策略适应性
用户规模扩展性	在用户从 40 → 80 增加时, 仍能保持良好的性能与鲁棒性

### (3) 总结和展望

#### 1. 总结

本文提出的 MODE-DRL 框架是首个将多目标分解进化算法 (MODE) 与深度强化学习 (DRL) 深度融合的研究, 专门针对 UAV 辅助 MEC 中动态多目标优化问题。通过:

- 双向匹配策略提升种群多样性;
- 向量奖励函数保留目标间冲突信息;
- PPO 与 DDPG 集成实现策略快速适应;

实验结果表明, 该框架在延迟、能耗、任务完成数量等关键指标上均显著优于现有方法, 具备良好的收敛性、分布性与适应性, **为 UAV 辅助 MEC 的车联网系统中实时多目标决策提供了一种具有可扩展性的全新范式。**

#### 2. 展望

本篇文章目前仅考虑单 UAV, 未来可扩展至多机协同, 引入空域冲突避免与任务分工机制; 此外, 本文仅设计了仿真实验, 在未来可以在真实城市环境下进行验证, 结合真实交通流量、建筑遮挡、风速等因素, 提升模型实用性; 还可以进一步细化能耗模型, 考虑电池衰减、充电策略等, 实现绿色计算; 还可以引入元学习或迁移学习, 使模型在不同城市或交通场景中快速适应。

## 五、论文五

### (1) 论文相关信息

- 标题: Federated Learning Assisted Intelligent IoV Mobile Edge Computing
- 作者: Haoyu Quan, Qingmiao Zhang, Junhui Zhao
- 出处: IEEE TRANSACTIONS ON GREEN COMMUNICATIONS AND NETWORKING (TGCN)
- 日期: 2025年3月
- 英文摘要:

As a crucial solution to the insufficient computing resources of device in Internet of Vehicles (IoVs) systems, mobile edge computing (MEC) has received widespread attention, especially for tackling delay-sensitive tasks in IoVs. This paper focuses on a multi-roadside units (RSUs) multi-vehicle IoV MEC system with different task delay thresholds. To enhance the system performance in terms of task completion rate, service

delay, and energy consumption, a hybrid multi-agent deep reinforcement learning algorithm (HMADRL) based adaptive joint optimization scheme was proposed for computation offloading and resource allocation strategies. Further, a centralized computation offloading and distributed resource allocation framework is designed to reduce communication overhead between multiple agents, and federated learning (FL) technology is used to protect user privacy and accelerate training. The numerical results validate that our scheme improves the performance of IoV MEC system significantly while satisfying system resource and task delay constraints.

- 中文摘要:

作为解决车联网 (IoVs) 系统中设备计算资源不足的关键方案，移动边缘计算 (MEC) 受到了广泛关注，尤其是在处理车联网中的延迟敏感任务方面。本文聚焦于一个多路侧单元 (RSUs) 和多车辆的车联网MEC系统，该系统具有不同的任务延迟阈值。为了提高系统在任务完成率、服务延迟和能耗方面的性能，提出了一种基于混合多智能体深度强化学习算法 (HMADRL) 的自适应联合优化方案，用于计算卸载和资源分配策略。此外，设计了一个集中式计算卸载和分布式资源分配框架，以减少多个智能体之间的通信开销，并采用联邦学习 (FL) 技术来保护用户隐私并加速训练。数值结果验证了我们的方案显著提高了车联网MEC系统的性能，同时满足了系统资源和任务延迟的约束。

- 英文关键字:

Internet of Vehicle (IoV), mobile edge computing (MEC), computation offloading, resource allocation, hybrid multi-agent deep reinforcement learning algorithm (HMADRL), federated learning (FL).

- 中文关键字:

车联网、移动边缘计算、计算卸载、资源分配、混合多智能体深度强化学习算法、联邦学习。

## (2) 论文相关分析

### 1.研究背景

随着车联网 (IoV) 技术的迅速发展，车辆已成为智能化的数据生成源。这些数据需要及时处理以实现自动驾驶、智能交通和车载娱乐等应用。然而，车载设备的计算能力有限，且这些应用往往对计算和延迟有高要求。为了解决这个问题，移动边缘计算 (MEC) 成为了一个有前景的解决方案。MEC通过将计算资源部署到车联网边缘（如路侧单元RSU）来减少通信延迟，提高计算能力。尽管MEC提高了计算效率，但其资源受限、系统调度复杂性大，且引入额外的通信延迟，使得如何优化计算卸载和资源分配成为关键。

为了应对这一挑战，许多研究提出了通过优化计算卸载和资源分配策略来提高MEC系统的效率，尤其是在多任务和高延迟环境下。传统的优化方法大多将计算卸载和资源分配问题拆解为子问题来解决，带来了较高的计算复杂度。最近，深度强化学习 (DRL) 已被广泛应用于优化MEC系统，但传统DRL方法往往依赖于全局信息并面临数据隐私问题。

### 2.核心创新与贡献

本篇文章提出了一个融合联邦学习与混合多智能体的DRL，主要创新性贡献如下：

- 提出了**适应性JCORA优化方案**，针对多RSU和多车辆的MEC系统，采用了集中式计算卸载策略与分布式资源分配策略，并且能够动态调整这些策略来优化任务的完成率、服务延迟和能耗。
- 设计了**混合多智能体深度强化学习 (HMADRL) 算法**，将计算卸载和资源分配优化任务分解为两个子任务，通过不同的代理来优化，且每个代理只需本地状态信息，避免了传统方法中对全局状态的依赖。这种设计有效减少了广播通信的开销，并保护了用户隐私。

- **集成了联邦学习 (FL)**，通过将FL技术引入HMADRL算法，解决了用户隐私和数据安全问题，使得各代理能够在本地训练和共享模型参数，从而加速训练过程并提高性能。

### 3.实验

仿真实验设置如下：

项目	内容
<b>场景</b>	1 km <sup>2</sup> 区域，1 个宏基站 + 3 个RSU + 最多 60 辆车
<b>任务模型</b>	任务到达时间、延迟阈值、数据量、CPU周期等服从泊松分布
<b>通信模型</b>	3GPP TR 36.885 标准信道模型
<b>算法对比</b>	6 个基线方案 (TBL1~3, MBL1~4)，涵盖随机、PSO、DRL、FL 等
<b>评价指标</b>	任务完成率、平均服务延迟、平均能耗、请求响应率

与最优基线模型MBL3相比，本文方法FL-HMADRL在任务完成率上提升了 **10.15%**，在平均服务延迟上降低了**8.7%**。随着车辆数量的增加，任务的能耗逐渐增大，但通过合理的资源调度和优化，能量消耗得到了有效控制。在车辆数较多时，平均能耗显著优于其他方案，并且仍然可以保持稳定性能。实验结果还表明，采用FL的方案相比其他方案在训练效率和系统性能上都有显著提升。

## (3) 总结和展望

### 1.总结

本文提出的 FL-HMADRL 框架是首个将联邦学习与混合多智能体DRL深度融合的研究，专门针对多RSU、多车辆、异构任务的IoV MEC 场景。通过：

- 集中式卸载决策 (D3QN) + 分布式资源分配 (MAPTD3)；
- FL 参数聚合 保护隐私、提升训练效率；
- 动态任务建模与多目标 reward 设计；

实验结果表明，该方案在任务完成率、延迟、能耗等关键指标上均显著优于现有方法，具备良好的实时性、扩展性与适应性。

### 2.展望

未来，基于本文的方法，可以在以下方面进行改进：

- 进行多车协同与移动性建模，引入车辆高速移动、信道时变、切换机制，提升模型真实性与鲁棒性。
- 支持跨RSU任务迁移和边缘-云协同计算，提升系统容量。
- 探索异步FL、个性化FL、梯度压缩等技术，进一步降低通信开销。
- 结合能量收集RSU或绿色能源，优化能耗模型，实现可持续边缘计算。
- 在真实车联网测试平台（如Simu5G、Veins）上部署算法，验证其工程可行性。

## 六、论文六

### (1) 论文相关信息

- 标题: Potential Game Based Distributed IoV Service Offloading With Graph Attention Networks in Mobile Edge Computing

- 作者: Qinting Jiang, Xiaolong Xu, Muhammad Bilal, Jon Crowcroft, Qi Liu, Wanchun Dou

- 出处: IEEE TRANSACTIONS ON INTELLIGENT TRANSPORTATION SYSTEMS (TITS)

- 日期: 2024年9月

- 英文摘要:

Vehicular services aim to provide smart and timely services (e.g., collision warning) by taking the advantage of recent advances in artificial intelligence and employing task offloading techniques in mobile edge computing. In practice, the volume of vehicles in the Internet of Vehicles (IoV) often surges at a single location and renders the edge servers (ESs) severely overloaded, resulting in a very high delay in delivering the services. Therefore, it is of practical importance and urgency to coordinate the resources of ESs with bandwidth allocation for mitigating the occurrence of a spike traffic flow. For this challenge, existing work sought the periodicities of traffic flow by analyzing historical traffic data. However, the changes in traffic flow caused by sudden traffic conditions cannot be obtained from these periodicities. In this paper, we propose a distributed traffic flow forecasting and task offloading approach named TFFTO to optimize the execution time and power consumption in service processing. Specifically, graph attention networks (GATs) are leveraged to forecast future traffic flow in short-term and the traffic volume is utilized to estimate the number of services offloaded to the ESs in the subsequent period. With the estimate, the current load of the ESs is adjusted to ensure that the services can be handled in a timely manner. Potential game theory is adopted to determine the optimal service offloading strategy. Extensive experiments are conducted to evaluate our approach and the results validate our robust performance.

- 中文摘要:

车载服务旨在利用近期人工智能技术的进展和移动边缘计算中的任务卸载技术，提供智能和及时的服务（例如，碰撞警告）。在实际应用中，车联网（IoV）中的车辆数量通常会在某个地点激增，导致边缘服务器（ESs）严重过载，从而使服务的交付延迟非常高。因此，协调边缘服务器的资源和带宽分配，以减轻流量激增的影响，具有重要的现实意义和紧迫性。为解决这一挑战，现有研究通过分析历史交通数据来寻找流量的周期性。然而，由于突发的交通状况造成的流量变化无法从这些周期性中得到预测。

本文提出了一种分布式交通流预测和任务卸载方法，命名为 TFFTO，用于优化服务处理中的执行时间和能耗。具体而言，我们利用图注意力网络（GATs）进行短期交通流量预测，并利用预测的交通量来估算在随后的时段内卸载到边缘服务器的服务数量。基于这一估算，调整当前边缘服务器的负载，确保服务能够及时处理。此外，采用潜在博弈理论来确定最优的服务卸载策略。

通过大量实验评估了我们的方法，结果验证了其强大的性能。

- 英文关键字:

Service offloading, edge computing, graph attention network, game theory, flow forecasting.

- 中文关键字:

## (2) 论文相关分析

### 1. 研究背景

随着智能交通系统的发展，**车联网 (IoV, Internet of Vehicles)** 成为缓解城市交通拥堵、提升出行体验的重要技术。IoV中的车辆通常需要运行计算密集型任务（如碰撞预警、自动驾驶等），但车辆本身的计算资源有限，难以满足实时性要求。

当前存在以下现有问题：

- 车辆任务卸载到边缘服务器 (Edge Servers, ES) 或云服务器 (Cloud Server, CS) 时，边缘服务器可能因突发交通流量而过载，导致服务延迟高。
- 传统方法多基于历史交通数据的周期性分析，无法应对突发交通状况（如事故、临时拥堵等）。
- 用户分布具有时空动态性，边缘服务器负载不均衡，资源浪费或超载问题严重。

本文提出了一种**分布式的任务卸载策略**，结合**短期交通流预测与博弈论优化**，来降低服务处理延迟、减少车辆能耗，以及实现边缘服务器负载均衡。

### 2. 核心创新与贡献

本篇论文提出了一种名为 **TFFTO (Traffic Flow Forecasting and Task Offloading)** 的分布式服务卸载框架。其中使用了**图注意力网络 (GAT)** 来进行短期交通流预测，以及**用势博弈 (Potential Game)** 来优化任务卸载决策。

该框架主要有以下创新点：

- 利用GAT对区域交通流进行短期预测，捕捉节点间复杂关系，提升预测精度；
- 设置了负载感知调整机制，即根据预测结果动态调整边缘服务器负载，避免突发流量造成过载；
- 用势博弈建模了卸载过程，证明了任务卸载存在纳什均衡，保证分布式决策的收敛性和稳定性；
- 使用三层博弈结构，分别处理本地 vs 卸载、边缘 vs 云、RSU vs BS 之间的博弈关系，提升策略合理性；
- 提出分布式的任务卸载算法，避免中心化调度带来的通信开销和单点故障。

### 3. 实验

实验设置如下：

- **数据集：** 使用2014年9月南京真实交通数据，包括436个RSU（路侧单元）采集的数据
- **仿真环境设置：**
  - 8个RSU，覆盖200米范围
  - 云服务器距离500公里
  - 车辆任务大小：5000KB，计算量：1 Gigacycle
  - 车辆本地计算能力：0.4~1.0 GHz
  - RSU/BS/CS计算能力分别为10/20/10 GHz
- **与以下方法进行对比：**
  - LCFA：全部本地计算

- COFA：全部卸载到最近RSU
- F-TORA：已有资源分配方法
- ACCO：基于博弈的协同卸载方法

实验结果如下：

指标	TFFTO表现
平均处理与传输时间	比ACCO降低约30%，比LCFA和COFA降低5倍以上
系统能耗	比ACCO降低25%，比F-TORA降低15%
系统总开销	比ACCO优化25%，比COFA优化80%
预测精度 (MAPE)	收敛至约2%，预测误差极小
算法收敛性	快速收敛至纳什均衡，决策轮次与车辆数呈线性关系

### (3) 总结和展望

#### 1.总结

本文提出了一种融合图注意力网络与势博弈理论的分布式任务卸载方法TFFTO，有效解决了IoV中因交通流突发变化导致的边缘服务器负载不均衡问题。实验结果表明，TFFTO在延迟、能耗、系统开销等方面均优于现有方法，具备良好的扩展性、收敛性和实用性。

#### 2.展望

未来可进行如下工作：

- **5G场景下的任务拆分**：支持将一个任务拆分为多个子任务，提升卸载灵活性
- **车与车 (V2V) 协同卸载**：利用车辆之间的通信能力，实现更高效的边缘协同计算
- **更复杂的交通场景建模**：如城市级大规模路网、跨区域协同卸载等

## 七、论文七

### (1) 论文相关信息

- 标题：Dynamic Task Offloading for Multi-UAVs in Vehicular Edge Computing With Delay Guarantees: A Consensus ADMM-Based Optimization
- 作者：Rui Huang, Wushao Wen, Zhi Zhou; Chongwu Dong, Cheng Qiao, ZhiHong Tian
- 出处：IEEE TRANSACTIONS ON MOBILE COMPUTING (TMC)
- 日期：2024年12月
- 英文摘要：

Within the paradigm of forthcoming 6G network infrastructures, unmanned aerial vehicles (UAVs), functioning as principal conveyances, are projected to emerge as pivotal enablers in the nascent domain of the low-altitude economy. UAVs are poised to embrace various innovative applications, including latency-sensitive and compute-intensive services. However, UAVs are constrained by their energy capacity and computational resources, rendering them insufficient for fulfilling the increasingly

rigorous service demands in the future. To address these challenges, our investigation focuses on the innovative UAV-based Vehicular Edge Computing (UVEC) framework, incorporating Vehicular Edge Computing (VEC) in UAV systems to bolster service reliability. A UAV can enhance its mission duration by dynamically selecting suitable vehicles for computation offloading and adaptively adjusting the task offloading ratio between vehicles and the edge server. By integrating vehicle selection and task offloading scheduling in the UVEC framework, we investigate the optimization of energy efficiency while satisfying the statistical delay and the buffer constraints for UAVs. To deal with the proposed problem, a distributed algorithm is designed by jointly considering the vehicle selection for task offloading radio to vehicles and the edge server. The stochastic network calculus (SNC) is employed to derive performance bounds for the statistical delay and constraints, enabling robust analysis and optimization of network performance. After that, we leverage linear transformation techniques to reformulate the original problem into a linear framework, enabling the application of the Alternating Direction Method of Multipliers (ADMM) algorithm to efficiently solve the transformed problem. Theoretical analysis and simulation results show that our algorithm converges while effectively satisfying service reliability constraints within the desired targets, outperforming benchmark schemes in terms of efficiency while meeting task delay and error-rate bounded constraints.

- 中文摘要:

在即将到来的 6G 网络基础设施范式中，无人机 (UAV) 作为关键的通信与计算载体，预计将在低空经济这一新兴领域中发挥至关重要的作用。无人机有望支持多种创新型应用，包括对时延敏感和计算密集型的服务。然而，无人机受限于其能源容量和计算资源，难以满足未来日益严苛的服务需求。

为应对这些挑战，本文提出了一种创新性的**基于无人机的车载边缘计算 (UVEC) 框架**，在无人机系统中引入**车载边缘计算 (VEC)** 机制，以提升服务的可靠性。通过动态选择合适的车辆进行任务卸载，并自适应地调整任务在车辆与边缘服务器之间的卸载比例，无人机能够有效延长任务执行时间和续航能力。

在所提出的 UVEC 框架中，我们综合考虑车辆选择与任务卸载调度，以在满足无人机的统计时延和缓冲约束的前提下，实现能效最优。针对该优化问题，本文设计了一种分布式算法，联合考虑了任务卸载到车辆与边缘服务器时的车辆选择问题。

此外，采用随机网络演算 (SNC) 方法推导出统计时延及其约束的性能界，从而实现对网络性能的稳健分析与优化。随后，我们运用线性变换技术将原始问题重新表述为线性框架，使得可以利用交替方向乘子法 (ADMM) 高效求解该转化后的问题。

理论分析与仿真结果表明，所提出的算法能够有效收敛，并在预设目标范围内满足服务可靠性约束；同时在能效、任务时延和误差率受限的条件下，显著优于现有基准方案。

- 英文关键字:

6G, ADMM, stochastic network calculus, unmanned aerial vehicles, vehicular edge computing.

- 中文关键字:

6G、交替方向乘子法、随机网络演算、无人机、车载边缘计算。

## (2) 论文相关分析

### 1. 研究背景

随着6G通信与低空经济的发展，**无人机（UAV）**被广泛应用于智能交通、巡逻监控、应急救援等场景。这些任务通常具有高计算需求、极低延迟要求( $<1\text{ms}$ )和极高可靠性( $>99.99999\%$ )。然而，UAV自身受限于**电池容量和计算能力**，难以满足上述严苛的服务质量(QoS)需求。

面对以下研究挑战：

- **车辆移动性强**：导致网络拓扑和信道状态频繁变化
- **资源异构性强**：车辆与UAV之间计算与通信能力差异大
- **任务到达不确定**：难以预测任务负载，造成队列拥塞
- **服务可靠性要求高**：传统平均性能指标无法满足延迟敏感型服务的确定性保障

本文提出一种**分布式的任务卸载策略**，在保证延迟和可靠性约束的前提下，最大化UAV的能效，实现UAV与车辆之间的协同计算。

### 2. 核心创新与贡献

本篇论文构建了一个融合无人机与车载边缘计算资源的**UVEC框架**，使无人机能够通过与地面车辆协同，实现任务卸载与计算资源共享，从而提升系统整体计算能力与任务执行效率。为了在动态环境中保证任务的稳定传输与执行，研究引入了**随机网络演算**(Stochastic Network Calculus, SNC)理论，建立了服务可靠性模型，定量分析任务传输过程中延迟违例概率与缓存溢出概率，从而为系统提供可计算的可靠性保障。在上述模型基础上，论文构建了一个以能效最大化为目标的联合优化问题。该问题同时优化车辆选择策略与任务卸载比例，并考虑多重约束条件，包括任务时延、缓存容量以及服务可靠性约束，确保系统在能耗与性能间取得平衡。针对优化问题的非凸性与分布式特征，研究提出了一个**基于共识ADMM(Alternating Direction Method of Multipliers)的分布式算法**，命名为**JTODAOR**。该算法通过线性变换将原始非凸问题转化为可求解的凸优化问题，从而实现高效的分布式求解与资源协调。最后，论文从**目标函数收敛性、对偶变量收敛性以及残差收敛性**三个层面，严格证明了算法的数学稳定性与最优化，确保在多节点交互与资源共享过程中，系统能够收敛到全局或近似最优解。

概括来讲，主要分为以下五点：

类别	内容
系统建模	提出UAV-based Vehicular Edge Computing (UVEC) 框架，融合UAV与车辆边缘计算资源
可靠性建模	引入随机网络演算(SNC)，量化任务传输延迟违例概率与缓存溢出概率，建立服务可靠性模型
优化目标	构建能效最大化问题，联合优化车辆选择与任务卸载比例，满足延迟、缓存、可靠性等多重约束
算法设计	提出基于共识ADMM的分布式算法(JTODAOR)，通过线性变换将非凸问题转化为可解的凸问题，实现分布式求解
理论分析	证明算法在目标函数、对偶变量、残差三个层面均具收敛性，保证算法稳定性与最优化

### 3.实验

实验设置如下：

- **场景**: 1km×1km区域，4个UAV，多个车辆，1个基站+边缘服务器
- **车辆移动模型**: 基于马尔可夫跳过程的随机移动模型
- **任务参数**: 每UAV每时隙生成固定大小任务，可卸载至车辆或边缘服务器

本文将本文方法与以下几个方法进行了对比：

- Edge Server Only
- Vehicle Only
- Average Ratio
- PMASAC (基于强化学习)
- EAVS (基于PPO)
- ETORS (基于拉格朗日优化)

本文方法比Vehicle Only提升约7%，优于PMASAC与EAVS，略低于ETORS但差距小；在服务可靠性上高达97%，优于其他所有算法（最高提升16%）；平均延迟约11秒，远低于Edge Only（28秒），与DRL方法相当；队列波动最小，拥塞控制能力强，并且随任务大小与车辆数量增加，仍保持稳定性能优势。

## (3) 总结和展望

### 1.总结

本论文在车联网（IoV）与移动边缘计算（MEC）交叉领域中，提出了一种面向多UAV系统的分布式任务卸载框架UVEC，通过融合随机网络演算与共识ADMM优化算法，实现了：

- **高可靠性**: 满足6G mURLLC场景下的延迟与错误率约束
- **高能效**: 最大化UAV能效，延长任务执行时间
- **强适应性**: 适应车辆高动态性与任务不确定性
- **分布式求解**: 降低通信开销，提升系统可扩展性

### 2.展望

基于论文现有工作，在未来可以在以下几个方面进行改进：

- 支持一个任务拆分为多个子任务，提升卸载灵活性
- 引入UAV间通信与协同计算机制
- 考虑红绿灯、道路拓扑、车速限制等真实因素
- 结合交通流预测与任务负载预测，实现更智能的卸载决策

## 八、论文八

### (1) 论文相关信息

- 标题: Federated MADDPG-based Collaborative Scheduling Strategy in Vehicular Edge Computing
- 作者: Songxin Lei, Huijun Tang, Chuangyi Li, Xueying Zhang, Chenli Xu, Huaming Wu
- 出处: IEEE TRANSACTIONS ON MOBILE COMPUTING (TMC)
- 日期: 2025年7月
- 英文摘要:

In Vehicular Edge Computing (VEC), vehicles offload computational tasks to Roadside Units (RSUs) equipped with edge servers to achieve efficient processing. Considering that vehicles switch connections between RSUs during high-speed movement, obtaining the state information of other RSUs is crucial for achieving global collaborative decision-making. However, frequent sharing of RSUs' state data during the training of scheduling models may result in privacy leakage risks. To address this issue, we federally train a joint scheduling model for task offloading and resource allocation without the need for state sharing among RSUs. We prove that the proposed task offloading problem influenced by resource allocation is a strict multi-node non-cooperative potential game problem, and use the potential function as the reward function for Multi-Agent Deep Deterministic Policy Gradient (MADDPG). Finally, we propose the Fed-MADDPG algorithm to find the equilibrium point of task offloading and apply the gradient descent method and the Lagrange multiplier method to maximize the average task completion rate among RSUs under constraints, ensuring the framework has optimal computational and transmission performance. We conduct simulation experiments using realworld datasets, and the results show that this method has superior performance compared to previous approaches.

- 中文摘要:

在车载边缘计算 (Vehicular Edge Computing, VEC) 中，车辆将计算任务卸载到配备边缘服务器的路侧单元 (RSU)，以实现高效处理。考虑到车辆在高速移动过程中会切换与不同RSU的连接，获取其他RSU的状态信息对于实现全局协作决策至关重要。然而，在调度模型训练过程中频繁共享RSU的状态数据可能导致隐私泄露风险。为了解决这一问题，我们通过联邦方式训练一个联合调度模型，用于任务卸载和资源分配，而无需在RSU之间共享状态信息。我们证明了所提出的受资源分配影响的任务卸载问题是一个严格的多节点非合作潜在博弈问题，并将潜在函数作为多智能体深度确定性策略梯度 (MADDPG) 的奖励函数。最后，我们提出了Fed-MADDPG算法，用于找到任务卸载的均衡点，并结合梯度下降法和拉格朗日乘子法，在约束条件下最大化RSU的平均任务完成率，从而保证框架在计算和传输性能上的最优性。我们使用真实数据集进行了仿真实验，结果表明，该方法在性能上优于以往的方法。

- 英文关键字:

Vehicular Edge Computing, Joint Scheduling Model, Multi-Agent Deep Reinforcement Learning, Federated Learning.

- 中文关键字:

车载边缘计算、联合调度模型、多智能体深度强化学习、联邦学习。

## (2) 论文相关分析

### 1.研究背景

随着车联网 (Internet of Vehicles, IoV) 和移动边缘计算 (Mobile Edge Computing, MEC) 的快速发展, 车载边缘计算 (Vehicular Edge Computing, VEC) 成为智能交通系统中的关键技术。VEC通过将车辆产生的计算任务卸载到部署在道路边缘的路侧单元 (RSU) 上, 实现低延迟、高效率的任务处理。然而, 车辆高速移动导致其与RSU的连接频繁切换, 传统的集中式调度方法难以适应动态环境。同时, 多RSU之间的协同调度需要共享状态信息, 这可能引发隐私泄露和安全风险。此外, 任务卸载与资源分配之间的耦合关系使得联合优化问题更加复杂。因此, 如何在保护隐私的前提下, 实现多RSU协同调度, 并动态优化任务卸载与资源分配, 成为当前研究的关键挑战。

### 2.核心创新与贡献

本文提出了一种基于联邦学习的协同调度模型, 实现了车辆边缘计算环境下任务卸载与资源分配的联合优化。在该框架下, RSU无需共享状态信息, 仅通过上传策略网络参数进行全局聚合, 从而有效保护数据隐私。为理论分析, 我们将任务卸载问题建模为严格的多节点非合作潜在博弈, 并证明该博弈存在纯策略纳什均衡, 从而保证算法的收敛性; 同时, 将资源分配子问题建模为凸优化问题, 并利用KKT条件求解最优解。基于此理论基础, 本文提出了**联邦多智能体深度确定性策略梯度算法** (Fed-MADDPG), 结合潜在博弈理论, 将潜在函数作为奖励函数引导智能体学习最优策略, 并采用Gauss-Seidel型块坐标下降 (BCD) 框架交替优化任务卸载与资源分配, 实现动态协同。为了验证算法性能, 我们使用真实车辆轨迹数据——成都滴滴GAIA数据集进行了仿真实验, 在不同交通密度和不同RSU计算能力条件下进行评估。实验结果表明, Fed-MADDPG在任务完成率、平均实现势及收敛性等方面均显著优于现有方法, 验证了其在车辆边缘计算环境下的有效性与优越性。

创新点可概括为以下几个方面:

- 问题建模方面: 将任务卸载建模为势博弈, 资源分配建模为凸优化, 首次在VEC中联合建模并求解;
- 算法设计方面: 提出Fed-MADDPG算法, 融合联邦学习与多智能体强化学习, 兼顾隐私与协同;
- 理论分析方面: 证明势博弈存在纳什均衡, 保证算法收敛性; 资源分配问题具备凸性, 可用KKT求解;
- 系统实现方面: 构建联邦训练框架, 实现RSU间的策略协同, 避免原始数据共享;
- 实验验证方面: 使用真实轨迹数据, 验证算法在多种交通场景下的鲁棒性与优越性;

### 3.实验

实验设置如下:

- **平台:** Python + TensorFlow + CUDA, RTX 3090 GPU \* 5
- **场景:** 3km道路, 8个RSU, 通信范围500m, 计算能力3~10GHz
- **数据:** 成都滴滴GAIA数据, 早/中/晚高峰各5分钟
- **对比算法:** ORM、ORL、MADDPG、MASAC
- **评估指标:**
  - 任务完成率 (Task Completion Rate)
  - 平均实现势 (Average Realized Potential)
  - 收敛性 (Cumulative Reward)

实验结果:

Fed-MADDPG在高密度交通下性能优势更明显，任务完成率提升显著。聚合周期为500时性能最优，平衡了全局协同与本地更新。随着RSU计算能力提升，Fed-MADDPG始终保持最优性能。不过，收敛速度略慢于MADDPG，但累计奖励更高，稳定性更好。

## (3) 总结和展望

### 1. 总结

本文在车联网与移动边缘计算交叉领域提出了一种联邦强化学习驱动的协同调度框架，有效解决了以下问题：

- **隐私保护**：避免RSU之间共享敏感状态信息；
- **协同优化**：实现任务卸载与资源分配的联合优化；
- **动态适应**：适应车辆高速移动带来的环境变化；
- **理论保障**：通过势博弈与凸优化理论保证算法收敛与最优化。

该研究为隐私保护下的多智能体协同调度提供了新思路，拓展了联邦学习在车载边缘计算中的应用边界。

### 2. 展望

未来研究可从以下几个方向展开：

- ①**云-边-端协同**：将模型扩展至云端，构建三层协同架构；
- ②**多任务类型支持**：引入异构任务（如图像识别、路径规划）建模；
- ③**通信开销优化**：设计更高效的参数聚合机制，降低通信频率；
- ④**安全机制增强**：引入差分隐私、同态加密等技术，进一步提升安全性；
- ⑤**实车部署验证**：在真实车联网环境中测试算法鲁棒性与实时性。

## 九、论文九

### (1) 论文相关信息

- 标题：Vehicular Edge Computing Meets Cache: An Access Control Scheme With Fair Incentives for Privacy-Aware Content Delivery
- 作者：Shunrong Jiang, Jinpeng Li, Guohuai Sang, Haiqin Wu, Yong Zhou
- 出处：IEEE Transactions on Intelligent Transportation Systems (TITS)
- 日期：2024年8月
- 英文摘要：

Vehicular Edge Computing (VEC) integrates mobile edge computing with traditional vehicular networks, which shifts the majority of computation and storage workload of resource-constrained vehicles to the edge nodes. The high mobility of vehicles usually leads to frequent network changes and connection interruptions, making data sharing more challenging in such dynamic and unstable environments. To address this issue, cache-based content delivery is considered a promising solution for efficient data sharing in VEC. However, access control and fair incentive distribution in privacy-aware data sharing are rarely taken into account in prior VEC-oriented studies. In this paper, we

propose RFIP-VEC, a Revocable access control scheme with Fair Incentive for Privacy-aware content delivery in VEC. Specifically, to enable anonymous authentication and conditional revocation, we construct a secure group signature scheme with formally proved security guarantees. Subsequently, based on our group signature scheme, we design a two-layer access control framework by employing proxy re-encryption. We also establish an evolutionary game theory model to analyze the effectiveness and fairness of the fair incentive in our scheme. Thus, our scheme can achieve flexible access control and fair incentive distribution with the assistance of edge nodes. Security analysis and experimental results demonstrate that the proposed scheme can achieve security goals with affordable cost in terms of network performance in VEC.

- 中文摘要:

车载边缘计算 (Vehicular Edge Computing, VEC) 将移动边缘计算与传统车载网络相结合，将资源受限车辆的大部分计算和存储负载转移到边缘节点。车辆的高移动性通常导致频繁的网络切换和连接中断，使得在这种动态且不稳定的环境下的数据共享更加困难。为解决这一问题，基于缓存的内容分发被认为是VEC中实现高效数据共享的一个有前景的解决方案。然而，以往面向VEC的研究中很少考虑隐私感知的数据共享中的访问控制与公平激励分配问题。本文提出了RFIP-VEC，一种面向VEC的隐私感知内容分发的可撤销访问控制与公平激励方案

(Revocable access control with Fair Incentive for Privacy-aware content delivery in VEC)。具体而言，为实现匿名认证和条件撤销，我们构建了一个具有形式化安全保证的安全群签名方案。随后，基于该群签名方案，我们设计了一个采用代理重加密的两层访问控制框架。同时，我们建立了进化博弈理论模型，用于分析方案中公平激励的有效性和公平性。因此，在边缘节点的辅助下，该方案可以实现灵活的访问控制与公平激励分配。安全性分析和实验结果表明，该方案能够在可接受的网络性能开销下，实现VEC中的安全目标。

- 英文关键字:

Edge computing, content delivery, cache, access control, group signature, fair incentives.

- 中文关键字:

边缘计算、内容分发、缓存、访问控制、群签名、公平激励。

## (2) 论文相关分析

### 1.研究背景

随着车联网 (VANETs) 和移动边缘计算 (MEC) 的发展，车辆不仅是数据的消费者，也逐渐成为数据的缓存节点和转发者。然而，车辆的高动态性导致了网络拓扑频繁变化，传统的中心化内容分发机制难以满足低延迟、高可靠性的需求。

在这种背景下，**基于缓存的内容分发机制 (cache-based content delivery)** 成为一种有效的解决方案。但这也带来了以下挑战：

- **访问控制问题**: 缺乏对非授权车辆访问内容的有效限制；
- **激励机制问题**: 缓存命中车辆应获得奖励，但难以防止中间节点冒充；
- **隐私保护问题**: 车辆身份和行为数据容易被追踪或滥用；
- **撤销机制问题**: 恶意车辆应被及时识别并撤销权限。

### 2.核心创新与贡献

作者提出了一种名为 **RFIP-VEC** (Revocable access control scheme with Fair Incentive for Privacy-aware content delivery in VEC) 的综合方案，具备以下特点：

- **双层访问控制机制**:

- 第一层：内容提供者（CP）对内容进行加密，确保内容机密性；
- 第二层：缓存命中车辆在边缘节点协助下，对内容进行重加密，确保只有请求车辆能解密。
- **公平激励机制：**
  - 利用边缘节点记录缓存命中车辆的行为，结合其贡献度进行奖励；
  - 引入演化博弈模型分析车辆行为，激励合作、抑制自私行为。
- **条件隐私保护与撤销机制：**
  - 提出一种安全的群签名方案（group signature），实现匿名认证与可追溯性；
  - 支持对恶意车辆的身份追踪与权限撤销。

论文还构建了一个基于双线性对的群签名方案，具备以下安全属性：

- **匿名性：** 车辆身份对外隐藏；
- **可追踪性：** 内容提供者可追踪签名者身份；
- **抗伪造性：** 防止恶意节点伪造签名；
- **可撤销性：** 支持对被撤销车辆的签名失效。

该方案在XDH、q-SDH等密码学假设下被证明是安全的，具备较强的理论支撑。

作者还引入演化博弈理论，对车辆的内容缓存与转发行为进行建模：定义了“主动节点”与“自私节点”两类角色，并设计策略空间（缓存、转发、拒绝转发），然后分析策略演化过程，证明系统最终会趋于纳什均衡，最后通过“多劳多得”的奖励机制，激励车辆积极参与内容分发。

### 3.实验

本篇论文想验证 RFIP-VEC 安全访问控制与激励机制在实际车联网环境中的可行性，重点关注以下几个方面：

- 计算开销是否适合资源受限的车辆设备
- 通信开销是否合理
- 网络性能（延迟、丢包率等）表现
- 相较其他方案的优势

实验设置如下：

- **平台：**
  - 计算性能测试：PBC 库模拟加密/签名操作（CPU i7-10750H，12GB 内存，Ubuntu 18.04）
  - 网络性能测试：ndnSIM（基于 NS-3 的 NDN 模拟器）
- **对比方案：** SEAF、ESAC、w/o 加密方案
- **测试指标：** 加密/解密时间、端到端延迟、丢包率、通信开销

**实验结果如下**

#### 1. 计算性能

- 第一层加密约 36ms，第二层约 23ms；解密速度更快（第一层 14ms，第二层 1.87ms）
- 签名更新每撤销车辆约 1.62ms，适合动态车联网

由此可以看出，计算开销可接受，适合车辆端执行。

## 2. 网络性能

- 端到端延迟：原始密文约 13.02ms，重加密密文约 16.2ms
- 延迟增长 4%-38%，重加密增加略高但换来更强访问控制
- 高并发测试（30% 车辆同时请求）：延迟增长可控，丢包率低于 2%

实验结果表明本文方法在高密度、高并发场景下仍具良好鲁棒性

## 3. 对比分析

- RFIP-VEC 相较 SEAF、ESAC 提供更强的隐私保护与激励机制，并且综合计算与通信性能也表现良好。

总体来说，RFIP-VEC 在保证安全和隐私的同时，计算和通信开销适中，并且网络性能稳定，可扩展性强，适用于高动态、高密度的车联网环境。

# （3）总结和展望

## 1. 总结

本论文在车联网与移动边缘计算交叉领域提出了一个**融合缓存、访问控制、隐私保护与激励机制**的综合方案，具备以下亮点：

- 理论创新：群签名方案与演化博弈模型的结合；
- 工程实用：双层加密机制适应高动态网络环境；
- 安全完备：支持匿名性、可撤销性与抗攻击性；
- 公平激励：有效激励车辆参与内容分发，抑制恶意行为。

可以说，这篇论文在车联网边缘计算与内容缓存融合的研究方向上做出了有价值的探索，尤其是在**隐私保护、访问控制与激励机制**三者之间的平衡设计上，具有较强的理论深度和工程实践意义。未来随着6G、边缘智能和车载计算平台的发展，这类研究将更加重要，值得持续关注和深入拓展。

## 2. 展望

尽管论文已做出较为系统的工作，但仍有一些值得进一步研究的方向：

1. **跨域协作缓存**：当前方案主要聚焦于单车群或局部边缘节点，未来可考虑多边缘节点之间的协同缓存与资源调度；
2. **AI 驱动的激励机制**：引入强化学习等方法，根据车辆行为动态调整奖励策略；
3. **区块链融合**：将激励机制与区块链结合，提升奖励分发的透明度与可信度；
4. **实际部署验证**：在真实车联网环境中部署测试，验证方案的可扩展性与鲁棒性；
5. **支持更细粒度的访问控制**：如基于属性加密（ABE）或策略隐藏机制，提升访问控制的灵活性与隐私性。

# 十、论文十

## （1）论文相关信息

- 标题：Scheduling for Maximizing the Information Freshness in Vehicular Edge Computing-Assisted IoT Systems
- 作者：Xin Xie, Tao Zhong, Heng Wang
- 出处：IEEE TRANSACTIONS ON INTELLIGENT TRANSPORTATION SYSTEMS (TITS)

- 日期: 2025年3月

- 英文摘要:

Vehicular edge computing (VEC), as an emerging computing paradigm, enables the timely processing of computing tasks at the network edge through on-vehicle servers, thereby meeting users' demands for information freshness. In this paper, we introduce the Age of Information (AoI) to measure information freshness and investigate the scheduling problem minimizing the long-term average AoI in VEC-assisted Internet of Things systems. The main challenge lies in the strong coupling between link scheduling and server selection under the location constraints of VEC. To address this issue, we design a scheduling strategy based on deep reinforcement learning and improve the neural network structure using a branch network approach, reducing complexity by decreasing the number of actions represented in the network's output layer. Moreover, we introduce an action masking scheme that accelerates the algorithm's convergence in this system. Numerical results show that the proposed scheduling algorithm can achieve up to a 25.4% performance gain compared to existing advanced algorithms.

- 中文摘要:

车载边缘计算 (Vehicular Edge Computing, VEC) 作为一种新兴的计算范式，通过车载服务器在网络边缘及时处理计算任务，从而满足用户对信息新鲜度的需求。本文引入信息时效性 (Age of Information, AoI) 作为衡量信息新鲜度的指标，并研究在 VEC 辅助的物联网系统中最小化长期平均 AoI 的调度问题。主要挑战在于 VEC 的位置约束下，链路调度与服务器选择之间存在强耦合关系。为解决该问题，我们设计了一种基于深度强化学习的调度策略，并通过分支网络方法改进神经网络结构，通过减少网络输出层所表示的动作数量来降低复杂度。此外，我们引入了动作屏蔽机制，加快算法在该系统中的收敛速度。数值结果表明，所提出的调度算法相比现有先进算法，可实现最高达 25.4% 的性能提升。

- 英文关键字:

Age of Information, vehicular edge computing, scheduling, offloading, Internet of Things.

- 中文关键字:

信息时效性、车载边缘计算、调度、任务卸载、物联网

## (2) 论文相关分析

### 1. 研究背景

随着物联网 (IoT) 和车联网 (IoV) 的快速发展，越来越多的应用（如智能工厂、自动驾驶、增强现实等）对信息新鲜度 (Information Freshness) 提出了高要求。传统的延迟指标已无法全面反映数据时效性，因此引入了**Age of Information (AoI)** 作为衡量信息新鲜度的核心指标。在车载边缘计算 (Vehicular Edge Computing, VEC) 架构中，车辆作为可移动的边缘服务器，可以为 IoT 设备提供计算服务，降低任务处理延迟，提升信息新鲜度。然而，VEC 服务器的移动性带来了调度复杂性，如：

- 如何选择最优卸载目标（车辆 or 基站）？
- 如何协调链路调度与服务器选择？
- 如何在大状态/动作空间中高效学习最优策略？

因此，本文聚焦于在 VEC 辅助的 IoT 系统中，最小化长期平均 AoI 的调度问题，提出一种基于**深度强化学习 (DRL)** 的智能调度算法。

## 2.核心创新与贡献

- 在问题建模与系统建模方面，构建了一个**VEC辅助的IoT系统模型**，包括：
  - 固定位置的IoT设备
  - 可移动的VEC服务器（车辆）
  - 固定位置的基站（BS）
- 将任务卸载、链路调度、VEC位置约束等因素统一建模为**马尔可夫决策过程（MDP）**，并定义了**AoI演化模型**，综合考虑了任务生成、传输、计算和反馈全过程
- 在算法设计方面，提出一种**基于动作掩码的分支对决深度Q网络（Action Masking-Based Branching Dueling DQN, AM-BDQN）**，创新点包括：
  - **分支网络结构**：将每个服务器的动作空间独立建模，降低神经网络输出维度
  - **动作掩码机制**：屏蔽无效动作（如VEC不在覆盖范围内），加速收敛
  - **Dueling结构**：分别估计状态价值和动作优势，提升学习效率
- 性能验证：
  - 在多种系统规模、任务生成率、VEC覆盖范围下进行仿真实验
  - 与多种先进算法（DQN、Dueling DQN、A3C、Greedy、Sub-Optimal）对比
  - 结果显示：AM-BDQN在**收敛速度、稳定性、AoI性能**方面均优于对比算法，**最大性能提升达25.4%**

## 3.实验

实验设置如下：

- **平台**：Python + TensorFlow，CPU i7-12700HL，32GB RAM
- **系统模型**：
  - IoT设备：3-20个，任务生成率  $\lambda \in \{0.1, 0.9\}$
  - VEC服务器：1-3个，覆盖半径  $r \in \{0.3, 0.9\}$  km
  - 基站：1个，位置固定
- **对比算法**：Greedy、DQN、Dueling DQN、Sub-Optimal、A3C
- **训练参数**： $\gamma=0.99$ ,  $\epsilon=0.2$ , 学习率=0.0001, 经验回放=3000, batch=64

实验结果表明，任务生成率、VEC覆盖范围和系统规模均对系统信息时效性（AoI）有显著影响：随着任务生成率或系统资源增加，AoI下降，而覆盖范围缩小时，AoI上升。在各类场景下，提出的AM-BDQN 算法始终优于其他对比算法，最大可降低 AoI 25.4%，且在复杂系统中仍表现出较强的有效性和鲁棒性。此外，AM-BDQN 在约 300 轮内即可收敛，其收敛速度优于 DQN、Dueling DQN 和 A3C，并且动作掩码机制有效减少了无效探索，提高了算法的稳定性和性能。

## （3）总结和展望

### 1.总结

本文在车联网与移动边缘计算交叉领域中，针对**信息新鲜度优化问题**，提出了一个**高效、智能、可扩展的调度框架**。其核心贡献包括：

- **问题建模**：首次将AoI优化与VEC移动性、链路冲突、服务器选择统一建模为MDP
- **算法创新**：提出AM-BDQN，结合分支网络、动作掩码、Dueling结构，解决大动作空间问题
- **性能提升**：在多种场景下实现最高25.4%的AoI降低，收敛更快、稳定性更强

- 实用性：适用于智能矿山、V2X、工业IoT等高密度、高动态场景

## 2.展望

未来研究可从以下方向展开：

1. **引入能耗约束**：在优化AoI的同时考虑设备能耗与VEC续航
2. **多智能体协同**：采用多智能体强化学习（MARL）实现分布式调度
3. **任务优先级建模**：考虑不同任务的时效性差异，设计优先级感知的调度机制
4. **真实场景验证**：在实际车联网平台或智能矿区部署测试
5. **融合预测机制**：结合轨迹预测、任务预测，提升调度前瞻性

# 十一、论文十一

## (1) 论文相关信息

- 标题：Efficient Multi-User Resource Allocation for Urban Vehicular Edge Computing: A Hybrid Architecture Matching Approach
- 作者：Hongyang Xie, Haoqiang Liu, Huiming Chen, Shaohan Feng, Zhaobin Wei, Yonghong Zeng
- 出处：IEEE TRANSACTIONS ON VEHICULAR TECHNOLOGY (TVT)
- 日期：2025年1月
- 英文摘要：

Advanced in the proliferation of the Internet of Things (IoT), a plethora of functions have been integrated in vehicular networks and thereby transferred it into a smart network. However, the contradiction between the limited on-vehicle computing resource and the massive data collected by these IoT devices hinders the broader adoption of vehicular network as a vast variety of on-vehicle applications are latency-sensitive. To address this issue, vehicular edge computing has become a promising technology as it can offload a large number of tasks from its proximal vehicles. However, the offloading methods recently utilized are inefficient while dealing with multi-user vehicular networks under dynamic scenarios. To design a superior offloading method that can effectively and efficiently offload tasks from vehicles to servers, multiple objectives and constraints with various topologies should be considered. In this paper, instead of constructing a typical multi-user and multi-server vehicular edge computing scenario, a complex scenario with more uncertainties, i.e. urban scenario, is modeled. We propose a Hybrid Architecture Matching Algorithm (HAMA) to minimize the average time latency subject to the constraint on energy consumption and evaluate the proposed algorithm in the above two scenarios. Moreover, HAMA is constructed based on hybrid centralized-distributed architecture, which can process the centralized collected information on a distributed manner. Experimental results demonstrate that the matching algorithm can significantly reduce average time latency, achieving up to a 68% improvement compared to local execution.

- 中文摘要：

随着物联网（IoT）的快速发展，众多功能被集成到车载网络中，从而将其转变为智能网络。然而，有限的车载计算资源与这些物联网设备收集的大量数据之间的矛盾，阻碍了车载网络的广泛应用，因为许多车载应用对延迟非常敏感。为解决这一问题，车载边缘计算（VEC）成为一种有前景的技术，它能够将大量任务从邻近车辆卸载。然而，现有的卸载方法在动态场景下处理多用户车载网络时效率较低。为了设计一种能够高效、有效地将任务从车辆卸载到服务器的优越方法，需要综合考虑多目标、多约束以及各种拓扑结构。本文没有构建典型的多用户多服务器车载边缘计算场景，而是建模了具有更多不确定性的复杂场景，即城市场景。我们提出了一种混合架构匹配算法（Hybrid Architecture Matching Algorithm, HAMA），以在能源消耗约束下最小化平均时延，并在上述两类场景中对该算法进行了评估。此外，HAMA 基于混合集中-分布式架构构建，能够以分布式方式处理集中收集的信息。实验结果表明，该匹配算法能够显著降低平均时延，相比本地执行可实现高达 68% 的性能提升。

- 英文关键字：

Vehicular edge computing, matching algorithm, resource allocation, optimization algorithm.

- 中文关键字：

车载边缘计算、匹配算法、资源分配、优化算法。

## （2）论文相关分析

### 1.研究背景

随着5G、物联网（IoT）和智能交通系统（ITS）的快速发展，车联网（IoV）正逐步演变为具备感知、计算和通信能力的智能网络系统。然而，车载计算资源有限，而实时应用（如自动驾驶、人脸识别、AR导航）对低延迟和高可靠性提出了极高要求，导致传统本地计算或远程云计算难以满足需求。

移动边缘计算（MEC）作为解决方案，通过将计算任务卸载到RSU（路侧单元）或邻近车辆（Server Vehicle），可显著降低延迟。但在城市复杂交通环境下，车辆高速移动、拓扑频繁变化、任务密集且多样，使得多用户资源分配与任务卸载决策面临以下挑战：

- 如何动态匹配任务车辆与合适的计算节点（RSU或Server Vehicle）？
- 如何在满足能量约束的前提下最小化平均延迟？
- 如何设计兼顾集中式全局优化与分布式实时响应的架构？

为此，本文提出一种混合架构匹配算法（HAMA），用于解决城市车联网中多用户任务卸载与资源分配问题。

### 2.核心创新与贡献

- 城市场景建模更贴近现实：相比传统高速公路模型，**城市道路交通模型**更具不确定性与复杂性，本文构建城市道路交通模型考虑了以下几个方面：
  - 车辆随机速度（高斯分布）
  - 红绿灯、交叉口、转向行为
  - V2V（车车通信）与V2I（车路通信）混合拓扑
  - 切换延迟、排队延迟、传输延迟、计算延迟等多维延迟建模
- 提出混合架构匹配算法（HAMA）：
  - 集中式收集全局信息（如车辆位置、服务器负载、信道状态）
  - 分布式执行匹配决策，每个任务车辆基于偏好列表选择最优卸载目标
  - 支持多对一匹配（多个任务车辆 → 一个服务器，带配额限制）

- 引入能量约束，在满足能耗上限的前提下最小化平均任务处理延迟
- 算法设计兼顾效率与适应性：
  - 利用匹配理论（Matching Theory）构建任务车辆与服务器之间的双边偏好关系
  - 偏好列表基于延迟、能耗、信道质量、服务器负载等多维指标
  - 算法具备低复杂度、高可扩展性，适用于高车辆密度场景

### 3.实验

实验设置如下：

- **仿真平台：** Python + 自定义城市交通仿真器
- **场景参数：**
  - 30个RSU均匀分布
  - 21辆车（每时隙随机选2辆作为Server Vehicle）
  - 输入数据大小：3MB（可调）
  - CPU频率：RSU=6GHz, Server Vehicle=5GHz, 本地=0.8GHz
  - 带宽：25MHz（理想无干扰假设）
  - 背景噪声：-140dBm
- **对比算法：**
  - 本地执行（Local Execution）
  - 基础一对一匹配（Basic Matching）
  - 深度强化学习（DRL）方法

实验结果表明，任务数据量、服务器计算能力和车辆数量（交通密度）均对系统延迟有显著影响：随着任务数据量或车辆数量增加，延迟上升，而服务器CPU频率提升则能降低延迟。在各类场景下，HAMA 算法表现最优，延迟增长最慢，3MB任务下相比本地执行延迟可减少高达68%，在高密度车辆场景下平均延迟仅增加0.05秒，显示出良好的可扩展性、稳定性和高效的匹配性能。

## （3）总结和展望

### 1.总结

本文在车联网与移动边缘计算的交叉领域中，针对城市复杂交通场景下的多用户任务卸载问题，提出了一个高效、实用、可扩展的解决方案：

- 场景建模：构建城市级V2V+V2I混合拓扑，考虑移动性、交叉口、红绿灯等真实因素
- 算法设计：提出HAMA，结合匹配理论与混合集中-分布式架构，兼顾全局优化与实时响应
- 性能提升：平均延迟降低高达68%，在高密度、高负载场景下仍保持稳定
- 实用性：算法复杂度低，适配高动态车载网络，适合部署于城市RSU或边缘节点

### 2.展望

未来研究可从以下方向深入：

1. **引入动态信道分配机制：**解决当前“无干扰”假设的局限性，适应真实OFDM系统
2. **考虑任务优先级与QoS差异化：**为不同类型任务（如安全类 vs 娱乐类）提供差异化服务
3. **融合DRL与匹配理论：**利用DRL动态调整偏好权重，提升匹配智能化水平
4. **能量约束更细化：**考虑车辆电池状态、能量回收机制，实现绿色计算

## 十二、论文十二

### （1）论文相关信息

- 标题：Deadline-Aware Task Offloading for Vehicular Edge Computing Networks Using Traffic Light Data
- 作者：PRATHAM OZA, NATHANIEL HUDSON, THIDAPAT CHANTEM, HANA KHAMFROUSH
- 出处：ACM Transactions on Embedded Computing Systems (TECS)
- 日期：2024年1月
- 英文摘要：

As vehicles have become increasingly automated, novel vehicular applications have emerged to enhance the safety and security of the vehicles and improve user experience. This brings ever-increasing data and resource requirements for timely computation by the vehicle's on-board computing systems. To meet these demands, prior work proposes deploying vehicular edge computing (VEC) resources in road-side units (RSUs) in the traffic infrastructure with which the vehicles can communicate and offload compute-intensive tasks. Due to the limited communication range of these RSUs, the communication link between the vehicles and the RSUs — and, therefore, the response times of the offloaded applications — are significantly impacted by vehicle mobility through road traffic. Existing task offloading strategies do not consider the influence of traffic lights on vehicular mobility while offloading workloads onto the RSUs. This causes deadline misses and quality-of-service (QoS) reduction for the offloaded tasks. In this article, we present a novel task model that captures time and location-specific requirements for vehicular applications. We then present a deadline-based strategy that incorporates traffic light data to opportunistically offload tasks. Our approach allows up to 33% more tasks to be offloaded onto RSUs compared with existing work without causing deadline misses, maximizing the resource utilization of RSUs.

- 中文摘要：

随着车辆自动化水平的不断提高，涌现出了许多新的车载应用，以增强车辆的安全性与可靠性，并提升用户体验。这也带来了对车辆车载计算系统进行及时计算的不断增长的数据和资源需求。为满足这些需求，已有研究提出在交通基础设施中的路侧单元（RSU）部署车载边缘计算（VEC）资源，车辆可与其通信并将计算密集型任务卸载至RSU。然而，由于RSU的通信范围有限，车辆与RSU之间的通信链路以及卸载应用的响应时间会受到车辆行驶状态的显著影响。现有的任务卸载策略在将任务卸载到RSU时，并未考虑交通信号灯对车辆移动性的影响，这可能导致任务未能按时完成，从而降低服务质量（QoS）。本文提出了一种新的任务模型，用于捕捉车载应用的时间和位置相关需求。基于此，我们提出了一种基于截止时间的任务卸载策略，结合交通信号灯信息进行机会性卸载。实验结果表明，与现有方法相比，该方法可使多达33%的任务成功卸载至RSU而不产生截止时间违约，从而最大化RSU资源利用率。

- 英文关键字：

Edge computing, connected traffic infrastructure, task offloading.

- 中文关键字：

边缘计算、互联的交通基础设施、任务卸载

## (2) 论文相关分析

### 1. 研究背景

随着智能网联汽车（Connected and Automated Vehicles, CAVs）的发展，车载应用日益复杂，涵盖安全驾驶、信息娱乐、增强现实（AR）等多个领域。这些应用对计算资源和响应时效性提出了高要求。然而，车辆本地计算能力有限，难以满足实时性要求。

**车载边缘计算（Vehicular Edge Computing, VEC）** 通过将计算任务卸载到部署在路侧单元（RSU）上的边缘服务器，能有效降低延迟、提升服务质量（QoS）。但由于RSU通信范围有限，车辆移动性对任务卸载的成功率和时效性影响显著。

现有研究多关注任务计算量、带宽、能耗等因素，忽略了交通信号灯对车辆移动轨迹和通信时长的影响，导致任务在车辆离开RSU覆盖范围前无法完成，从而错过截止时间（deadline miss），降低系统资源利用率和服务质量。

### 2. 核心创新与贡献

#### 1. 提出新颖的任务模型

- 区分两类任务：
  - **时间型任务（Regular Tasks）**：具有固定截止时间
  - **距离型任务（Distance-based Tasks）**：截止时间取决于车辆行驶距离（如导航路径计算）
- 模型更贴近实际车载应用需求，尤其适用于城市交叉口、红绿灯等复杂交通场景

#### 2. 引入交通灯数据，精准建模车辆移动性

- 利用交通灯状态（红/黄/绿）、剩余时间、周期等数据，预测车辆在不同RSU下的**驻留时间（dwell time）**
- 建立车辆运动模型（匀速、加速、减速、停车等待），结合交通灯状态判断车辆行为

#### 3. 提出基于截止时间的任务卸载策略（Deadline-Based Offloading）

- 目标：最大化RSU任务卸载数量，同时确保所有任务在截止时间前完成
- 策略核心：尽可能“临近截止时间”完成任务，避免过早占用资源，提升资源利用率
- 三阶段RSU选择：

1. **下载RSU（RSUd）**：选择车辆 deadline 前仍在覆盖范围内的RSU
2. **计算RSU（RSUc）**：选择满足计算时间且靠近RSUd的RSU
3. **上传RSU（RSUu）**：选择靠近RSUc且能完成上传的RSU

#### 4. 支持动态交通环境

- 支持单车/多车、空链路/有前车等复杂场景
- 引入安全车距、跟车模型（car-following model），适应城市真实驾驶行为

### 3. 实验

仿真实验相关设置：

- **交通仿真：**VISSIM（微观交通流仿真器）
- **通信仿真：**Python 构建的 MBS（Main Base Station）模拟器
- **场景设置：**

- 城市单链路 (400–800米)
- 车速: 25–35 mph
- 交通流量: 400–1000 vphpl (vehicles per hour per lane)
- 任务类型: 时间型 + 距离型
- RSU数量与处理器数量可调

作者将本文方法与以下几个方法进行了对比:

- **Wait Time-Aware**: 考虑平均等待时间, 但不使用交通灯数据
- **Mobility-Aware**: 仅考虑车辆移动性, 无交通灯信息
- **Local Execution**: 本地执行, 不上传

实验结果表明, 交通流量、处理器数量、车速及驾驶行为等因素均会显著影响任务卸载性能。随着交通流量增加或车速提升, 车辆在RSU覆盖区的驻留时间缩短, 传统方法因未考虑交通灯与车辆动态行为, 任务超时率 (deadline miss) 最高达25%。相比之下, 本文提出的基于截止时间和交通灯感知的任务卸载方法在所有测试条件下均实现 **0% deadline miss**, 成功卸载更多任务并最大化资源利用率。此外, 在引入 Weidemann 74 跟车模型以模拟非理想驾驶行为的情况下, 该方法仍能将任务超时率降低约 **78%**, 展现出更强的鲁棒性与环境适应能力。

### (3) 总结和展望

#### 1. 总结

本文在车联网与移动边缘计算的交叉领域中, 提出了一种融合交通灯数据的截止时间感知任务卸载策略, 主要贡献如下:

- 在任务建模方面, 首次区分时间型与距离型任务, 贴近城市驾驶场景, 并且利用交通灯数据精准预测车辆驻留时间与行为。
- 在卸载策略方面, 提出“临近截止时间完成”策略, 最大化RSU利用率
- 在多种交通、通信、计算条件下均实现 0% deadline miss, 卸载任务数提升 33%

#### 2. 展望

未来研究可从以下方向拓展:

- 在网络级上进行优化, 从单链路扩展到城市级路网, 实现全局资源调度
- 支持任务链、DAG结构等复杂依赖关系
- 结合V2V通信, 实现车车协同计算
- 引入深度学习预测交通灯状态与车辆行为

## 十三、论文十三

### (1) 论文相关信息

- 标题: Reducing Computation, Communication, and Storage Latency in Vehicular Edge Computing
- 作者: Mostafa Kishani, Zdenek Becvar
- 出处: IEEE Conference on Vehicular Technology

- 日期: 2024年6月

- 英文摘要:

This paper addresses the challenge of optimizing communication, computation, and storage I/O caching in Vehicular Edge Computing (VEC) platforms for autonomous vehicles. The exponential data generated by the autonomous vehicles demands low-latency connectivity with nearby edge servers. However, the existing VEC platforms struggle to meet the performance requirements, especially in real-time applications like collision avoidance. This work proposes a novel algorithm for joint allocation of computing resources, storage I/O cache, and communication resources, considering the diverse priorities and demands of key vehicular services. Our approach integrates application-specific optimizations, prioritization, and joint latency reduction considering communication, computation, as well as storage. Accounting for distinct priorities and data access characteristics of various vehicular services, our proposed feasible solution, employing dual decomposition and Lagrangian relaxation, significantly reduces service latency by up to 64% compared to the current state-of-the-art resource allocation in vehicular edge computing.

- 中文摘要:

本文针对自动驾驶车辆的车载边缘计算 (Vehicular Edge Computing, VEC) 平台中通信、计算与存储I/O缓存优化的问题进行了研究。自动驾驶车辆产生的海量数据对与邻近边缘服务器的低延迟连接提出了极高要求。然而，现有的VEC平台难以满足实时应用（如碰撞避免）对性能的严格需求。为此，本文提出了一种新的联合分配算法，用于同时优化计算资源、存储I/O缓存和通信资源分配，并综合考虑关键车载服务的不同优先级和需求。该方法融合了面向应用的优化、任务优先级管理以及通信、计算和存储三方面的联合时延降低策略。针对不同车载服务的数据访问特征和优先级差异，本文基于对偶分解与拉格朗日松弛方法提出了可行的联合优化方案。实验结果表明，与现有最先进的VEC资源分配方法相比，该方案可将服务时延显著降低，最高可达 **64%**。

- 英文关键字:

Vehicular Edge Computing, Latency, Communication, Computation, Storage, Mobile Edge Computing.

- 中文关键字:

车载边缘计算、延迟、通信、计算、存储、移动边缘计算。

## (2) 论文相关分析

### 1. 研究背景

随着自动驾驶和智能网联汽车的发展，车载应用对计算、通信和存储资源的需求急剧增长。例如，碰撞避免、实时感知、地图更新等任务对低延迟和高可靠性提出了极高要求。

传统的**车载边缘计算 (VEC)** 研究多聚焦于：

- 计算卸载 (Computation Offloading)
- 通信资源分配 (Bandwidth Allocation)
- 网络缓存 (Network Caching)

但存储I/O延迟往往被忽视，尤其是在使用HDD或低端SSD的边缘服务器中，存储访问成为系统性能瓶颈。此外，不同车载服务（如碰撞避免 vs 软件更新）具有不同的优先级和资源需求，现有方法未能有效区分和优化。

因此，本文提出一种联合优化通信、计算与存储I/O缓存的资源分配方法，旨在最小化服务延迟，提升VEC平台的整体性能。

## 2.核心创新与贡献

本文的创新和贡献主要有以下几个方面：

- 系统建模全面：构建了一个完整的VEC系统模型，涵盖通信（上下行链路）、计算（CPU核心、FLOPS）、存储（I/O缓存、主存、读写延迟）等，并且每种服务由独立的 **Unikernel** 处理，支持服务隔离与资源定制。
- 设计了联合优化目标函数：函数的优化目标为：**最小化加权平均延迟 × 优先级 × 请求数**，其中，权重体现了服务重要性，如碰撞避免 > 地图更新。除此之外，函数还同时考虑了通信带宽分配、计算核心分配、以及I/O缓存大小分配。
- 算法设计高效：本篇论文采用对偶分解（Dual Decomposition）与拉格朗日松弛（Lagrangian Relaxation）方法，将原问题分解为三个子问题：
  1. **Unikernel 与基站关联**（通信优化）
  2. **计算资源分配**（CPU核心）
  3. **I/O缓存分配**（存储优化）

每个子问题均可高效求解，整体算法复杂度为多项式级

## 3.实验

实验设置如下

- **平台**：自定义仿真器 + 真实存储迹线
- **服务类型**：4类典型车载服务（见表I）
- **对比方法**：
  - ETICA：仅优化I/O缓存，忽略通信与计算
  - JOCS：联合优化通信与存储，忽略计算
  - WSVN：联合优化通信与计算，忽略存储
- **评价指标**：平均服务延迟、通信/计算/存储延迟占比、算法可扩展性

实验结果表明，所提出的联合资源分配算法在各类车载服务场景下均显著优于现有方法，最大可降低平均延迟达 **64%**，尤其在混合负载（Mix）场景中表现最优，得益于其优先级感知与计算、通信、存储的联合优化策略。延迟分解分析显示，通信延迟占总体延迟的 **39%-62%**，而存储延迟在随机访问模式下对系统性能影响显著，本文方法在三类延迟上均实现了有效降低。此外，可扩展性测试结果表明，算法复杂度随服务器数量线性增长，能够支持上万个 Unikernel 部署，具备在大规模城市级 VEC 系统中应用的可行性和高效性。

## (3) 总结和展望

### 1.总结

本文提出了一种面向车载边缘计算（VEC）的**通信-计算-存储三维资源联合优化框架**，在理论与实践上均实现了创新与突破。该框架首次将I/O缓存延迟纳入VEC资源优化目标，构建了完整的三维延迟模型；通过对偶分解与拉格朗日松弛方法，实现了多项式复杂度的高效联合资源分配。实验结果表明，该方法可将平均服务延迟降低高达 **64%**，在所有服务类型中均优于现有方案。同时，框架支持真实存储迹线、服务优先级管理与Unikernel隔离，具备良好的实用性与可扩展性，能够满足自动驾驶等高要求场景的性能需求。

## 2.展望

未来的研究工作可进一步从以下几个方向展开：在动态环境下实现实时优化，针对车辆高速移动场景进行在线资源重分配；通过多服务器协同支持跨服务器的任务迁移与联合调度；利用人工智能增强预测能力，基于深度学习模型预测服务负载与资源需求；实现能耗与延迟的联合优化，在性能与能源效率之间取得平衡；并在真实的车联网（CAV）测试平台上开展实车部署与验证，以全面评估系统的性能、稳定性与可行性。

# 十四、论文十四

## （1）论文相关信息

- 标题：DRL-Based Resource Orchestration for Vehicular Edge Computing With Multi-Edge and Multi-Vehicle Assistance

- 作者：Yaoyin Zhang, Wenhao Fan, Yang Yu, Yuan'an Liu

- 出处：IEEE TRANSACTIONS ON INTELLIGENT TRANSPORTATION SYSTEMS (TITS)

- 日期：2025年6月

- 英文摘要：

Vehicular Edge Computing (VEC) offers a promising framework for providing vehicles with low-latency and highly reliable services. By leveraging the underutilized computational resources of parked and moving vehicles commonly found in urban areas, a VEC system can enhance the performance of surrounding user devices and alleviate the loads on its edge servers. In this study, a resource orchestration scheme is introduced for a multi-device, multi-vehicle, and multi-edge scenario. Tasks from a device can be offloaded to its associated edge server, a neighboring edge server, a parked vehicle, or a moving vehicle. Our goal is to achieve the total task processing cost (comprising task processing latency and energy consumption) minimization across all devices through making strategies for task offloading and computational and communication resource allocation. We decompose the optimization problem and propose a Twin Delayed Deep Deterministic Policy Gradient (TD3)-based Deep Reinforcement Learning (DRL) algorithm. Furthermore, to accelerate the convergence speed of the algorithm, we optimize the uplink transmit power allocation sub-problem separately by designing a numerical algorithm. We analyze the complexity of the algorithm and assess its convergence. Through extensive simulations across 5 different scenarios, our proposed scheme outperforms 4 reference schemes, showcasing reductions in total task processing costs ranging from 15.13% to 38.59%.

- 中文摘要：

车载边缘计算 (Vehicular Edge Computing, VEC) 为车辆提供低延迟、高可靠性的服务提供了一种有前景的框架。通过利用城市中大量停驶车辆与行驶车辆所蕴含的闲置计算资源，VEC 系统不仅可以提升周边用户设备的性能，还能有效减轻边缘服务器的计算负载。本文针对多设备、多车辆、多边缘节点的复杂场景，提出了一种资源编排机制。在该机制中，设备的任务可卸载至其关联的边缘服务器、邻近边缘服务器、停驶车辆或行驶车辆。研究目标是在所有设备中，通过优化任务卸载策略及计算与通信资源分配，实现总任务处理成本最小化，该成本包括任务处理延迟和能耗两部分。为此，我们将优化问题进行分解，并提出了一种基于双延迟深度确定性策略梯度 (Twin Delayed Deep Deterministic Policy Gradient, TD3) 的深度强化学习算法。此外，为加快算法的收敛速度，我们单独优化了上行链路功率分配子问题，并设计了相应的数值算法。本文还分析了算法的复杂度与收敛性。通过在五种不同场景下的大量仿真实

验，结果表明，所提出的方案相较四种参考方法，可将总任务处理成本降低 **15.13%~38.59%**，表现出显著的性能优势。

- 英文关键字：

Vehicular edge computing, resource management, task offloading, parked vehicles, moving vehicles.

- 中文关键字：

车载边缘计算、资源管理、任务卸载、停放车辆、移动车辆。

## (2) 论文相关分析

### 1.研究背景

随着智能交通和自动驾驶的发展，车辆对低延迟、高可靠的计算服务需求日益增长。VEC通过将计算资源下沉到靠近车辆的边缘节点（如基站、路边单元），可以显著降低任务处理延迟，提升服务质量。

传统的VEC系统主要依赖部署在基站上的边缘服务器，但其计算能力有限，难以应对高密度的用户设备（如传感器、智能手机、AR眼镜等）产生的计算任务，容易造成**服务器过载、任务排队、服务质量下降**。

如何高效地进行任务卸载、通信与计算资源分配，在多设备、多边缘、多车辆的复杂环境中，仍是一个极具挑战性的问题。

### 2.核心创新与贡献

本文提出了一种**基于深度强化学习（DRL）的资源编排框架**，用于解决上述挑战。其主要贡献如下：

- 在系统建模与问题构建方面，本文构建了一个**三层系统模型**：设备层、边缘层、车辆层；设定了**六种任务卸载路径**：包括本地边缘、其他边缘、静止/移动车辆等。综合考虑了**任务延迟、能耗、车辆服务价格、通信资源、计算资源、车辆驻留时间**等多维约束。并构建了一个**混合整数非线性规划问题（MINLP）**，以此来最小化所有设备的**任务处理总成本**（延迟 + 能耗的加权和）。
- 提出了一种**基于 Twin Delayed Deep Deterministic Policy Gradient (TD3)** 的DRL算法，解决任务卸载与资源分配问题。为降低训练复杂度，将上行传输功率分配子问题单独提取，采用Dinkelbach数值算法高效求解。通过问题分解 + 混合优化策略，显著提升了算法收敛速度与求解质量。
- 在**5种不同场景下与4种基准方案**进行对比实验。实验结果表明，本文方案在**总任务处理成本**方面平均降低了 **15.13% ~ 38.59%**。文章还分析了不同参数（设备数量、车辆数量、数据大小、边缘资源等）对系统性能的影响，验证了方案的**鲁棒性与适应性**。

### 3.实验

实验设置如下：

- **仿真平台：** PyTorch 1.12.1
- **网络结构：** Actor 和 Critic 网络均为两层全连接网络 ( $2048 \rightarrow 1024$ )，激活函数使用 ReLU (隐藏层) 和 softmax/tanh (输出层)
- **训练参数：**
  - 学习率：Actor 为  $3 \times 10^{-5}$ , Critic 为  $3 \times 10^{-4}$
  - 折扣因子  $\xi = 0.99$ , 软更新权重  $\lambda = 0.995$

- 每 50 步更新一次 Actor 网络
- 经验回放池大小  $|R| = 50000$ , 批量大小  $I = 200$
- 训练轮数: 500 轮, 每轮 500 步
- **数据集:** 意大利博洛尼亚市真实车辆轨迹数据集, 覆盖早高峰、午间、晚高峰三个时段, 共 22,000+ 车辆

收敛性分析: 本文算法在约**290轮训练后收敛**, 优于TD3-only (340轮) 和DDPG (未收敛)。并且奖励曲线平滑, 说明算法稳定性好。

卸载策略演化分析: 初始阶段: 三类卸载目标比例接近 (随机策略); 训练中期: 边缘服务器卸载比例逐渐上升; 收敛阶段: 边缘服务器占比 **58.14%**, 移动车辆 **24.69%**, 静止车辆 **17.17%**。该实验结果表明: 系统倾向于将任务优先卸载到边缘服务器, 体现了其在延迟和能耗方面的综合优势; 车辆资源作为有效补充, 在边缘负载高时承担更多任务。

### (3) 总结和展望

#### 1. 总结

本文在车联网与移动边缘计算交叉领域提出了一种智能化、协同化、动态化的资源编排方案, 具有以下重要意义:

- **理论层面:** 构建了一个高度真实、复杂的多节点协同计算模型, 拓展了VEC系统的研究边界。
- **算法层面:** 提出TD3+Dinkelbach混合优化框架, 为类似MINLP问题提供了新的求解思路。
- **应用层面:** 通过引入车辆资源, 显著提升了边缘系统的服务能力, 适用于智慧城市、自动驾驶、AR导航等场景。

#### 2. 展望

尽管本文方案已具备较强实用性和扩展性, 但仍有一些方向值得进一步研究:

1. **车辆移动性建模更精细化:** 如考虑路线预测、速度变化、服务中断等, 提升任务迁移的可靠性。
2. **安全与隐私保护机制:** 如车辆节点的可信度评估、任务数据加密、激励机制设计等。
3. **跨区协同与任务迁移:** 支持车辆跨基站、跨区域的动态任务迁移与资源调度。
4. **与5G/6G网络融合:** 结合网络切片、边缘AI等技术, 进一步提升服务质量与资源利用率。

## 十五、论文十五

### (1) 论文相关信息

- 标题: Distributed Collaborative Computing for Task Completion Rate Maximization in Vehicular Edge Computing
- 作者: Lei Liu, Zitong Zhao, Jie Feng, Feng Xu, Yue Zhang, Qingqi Pei, Ming Xiao
- 出处: IEEE TRANSACTIONS ON INTELLIGENT TRANSPORTATION SYSTEMS (TITS)
- 日期: 2025年10月
- 英文摘要:

Benefiting from the outstanding advantages in speeding up task processing and saving energy consumption, vehicular edge computing has entered a period of rapid development. Given the sharp increase in application services, it is vital to fully utilize all available computation resources to guarantee personalized requirements from different users. Specially, a lot of idle vehicle resources can be exploited for task execution to improve the service experience. On the other hand, most works focus on the system performance and fail to guarantee diversified user demands. To this end, we propose a novel distributed collaborative computing scheme for task completion rate maximization (TCRM) in vehicular networks by taking into account both vertical and horizontal collaboration. The novelty of horizontal collaboration lies in the full use of available one-hop vehicle resources for task computing. In order to simultaneously guarantee the system-level performance and the user-level performance, TCRM aims to maximize the task completion rate while minimizing the energy consumption by intelligent resource optimization and task allocation. A TD3-based algorithm combined with the Dirichlet distribution is proposed to obtain the optimization decisions. Extensive simulations demonstrate that TCRM significantly improves performance compared to baseline algorithms.

- 中文摘要：

凭借在加速任务处理与降低能耗方面的显著优势，车载边缘计算 (Vehicular Edge Computing, VEC) 已进入快速发展阶段。随着应用服务数量的急剧增长，如何充分利用所有可用计算资源以满足不同用户的个性化需求变得至关重要。特别是，大量闲置的车辆计算资源可以被挖掘用于任务执行，从而提升整体服务体验。另一方面，现有研究大多侧重于系统性能优化，却未能兼顾用户多样化需求。为此，本文提出了一种用于最大化任务完成率 (Task Completion Rate Maximization, TCRM) 的分布式协同计算方案，在设计中同时考虑了垂直协同与水平协同。其中，水平协同的创新点在于充分利用可用的一跳邻近车辆资源进行任务计算。为了同时保障系统层面的性能与用户层面的体验，TCRM 通过智能资源优化与任务分配，在最大化任务完成率的同时最小化能耗。本文进一步提出了一种结合双延迟深度确定性策略梯度 (TD3) 算法与 Dirichlet 分布的优化方法，用于求解最优决策。大量仿真实验结果表明，TCRM 相较于基准算法能显著提升系统性能。

- 英文关键字：

Vehicular edge computing, edge intelligence, horizontal collaboration, computation offloading, task completion rate.

- 中文关键字：

车载边缘计算、边缘智能、横向协作、计算卸载、任务完成率。

## (2) 论文相关分析

### 1. 研究背景

随着智能交通、自动驾驶和车载应用的发展，车辆对低延迟、高可靠计算服务的需求日益增长。传统云计算因传输距离远、延迟高，难以满足实时性要求。

车联网边缘计算 (VEC) 通过将计算资源部署在靠近车辆的边缘节点（如RSU、基站），有效降低延迟，提升服务质量。

尽管VEC系统资源丰富，但存在以下问题：

- 边缘服务器负载不均，部分节点过载，导致任务无法及时完成；
- 车辆资源未被充分利用，尤其是一跳邻居车辆具备计算能力却未被调度；

- 用户级需求未被保障，大多数研究只优化系统级性能（如总延迟、能耗），忽视任务是否成功完成（即任务完成率）。

在动态、时变、资源耦合复杂的车联网环境中，传统优化方法难以实时响应。人工智能（AI），特别是深度强化学习（DRL），具备感知、决策与自适应能力，成为解决VEC资源调度问题的重要工具。

## 2.核心创新与贡献

本文针对车载边缘计算（Vehicular Edge Computing, VEC）中资源利用不足与用户需求多样化的問題，提出了一种面向任务完成率最大化（Task Completion Rate Maximization, TCRM）的分布式协同计算方案。该方案构建了由任务车辆、服务车辆和边缘服务器共同参与的协同计算架构，充分利用闲置车辆的计算资源，实现了垂直协同与水平协同的有机结合。其中，水平协同机制创新性地引入一跳邻近车辆参与任务计算，有效缓解了边缘节点的计算压力并提升了系统的资源利用率。

在优化目标上，TCRM 以任务完成率最大化与系统能耗最小化为双重目标，通过智能化的资源调度与任务分配，在兼顾系统整体性能的同时保障用户级服务体验。算法层面，本文设计了一种结合双延迟深度确定性策略梯度（TD3）与Dirichlet分布的联合优化方法，以处理高维连续动作空间下的任务卸载与资源分配问题，实现了稳定高效的策略学习。仿真结果表明，所提出的TCRM方案在任务完成率、能耗以及综合性能方面均显著优于现有基准算法，展现出卓越的稳定性与适应性。

## 3.实验

### 实验设置

- **平台：**PyTorch
- **场景：**多RSU + 多车辆（任务车辆 + 服务车辆）
- **参数变化：**车辆数量、边缘计算能力、任务数据量、单比特CPU周期、最大容忍延迟
- **对比算法：**
  - Local：仅本地处理
  - Random：随机卸载
  - Mix：混合策略
  - DDPG：深度确定性策略梯度

实验结果表明，所提出的 TCRM 方案在多种动态场景下均展现出优异的适应性与稳健性。随着车辆数量增加或系统负载上升，TCRM 能灵活调度车辆与边缘资源，实现高任务完成率与低能耗；当边缘计算能力增强时，算法能够高效协调多源资源，进一步提升整体性能。在数据量与计算复杂度增加的情况下，TCRM 通过智能节点选择与资源分配，有效平衡传输与计算压力，使完成率保持最稳定、能耗最低；同时，在任务容忍延迟放宽时，系统依然维持最高的任务完成率，验证了其在复杂、多变车联网环境中的高效性与鲁棒性。

## （3）总结和展望

### 1.总结

本文在车联网与移动边缘计算交叉领域提出了一种分布式协同计算框架TCRM，其核心价值体现在：

- **资源视角：**首次系统性整合一跳车辆资源，实现V2V、V2I、ES-ES三类协同，突破传统边缘资源瓶颈；
- **用户视角：**以任务完成率为优化目标，真正保障用户级服务质量；
- **算法视角：**提出TD3 + Dirichlet分布联合优化策略，解决高维连续决策问题，提升策略稳定性与适应性；

- 系统视角：在多种动态场景下均表现出色，具备良好的扩展性与实用性。

## 2.展望

该论文当前仅考虑一跳邻居，未来可拓展至多跳车辆资源，提升调度灵活性；此外，由于车辆与边缘节点的计算能力、能耗模型差异较大，未来可引入异构资源建模来解决这个问题。还可以在协同计算中引入区块链或联邦学习机制，保障数据安全与节点可信。

# 十六、大总结

## (1) 计算卸载与资源分配优化是核心研究主题

以上几乎所有论文都关注任务卸载（Task Offloading）与计算/通信资源分配的联合优化，研究从集中式优化（如凸优化、Lagrange松弛、ADMM）逐渐转向分布式与智能化算法：

- 典型算法：DDPG、TD3、PPO、Actor-Critic、深度Q网络等。（论文1、4、5、14、15）
- 采用混合集中-分布式架构（如HAMA、HMADRL、TCRM）以兼顾全局最优与低通信开销。

同时从单目标优化（如最小延迟）逐渐转向多目标平衡（延迟+能耗+可靠性+公平性）。 （论文4、10、15）

## (2) 无人机（UAV）与多跳协同通信成为热点

从上面的论文可以看出，因为UAV可扩展MEC的覆盖范围、动态部署通信中继等有点，**UAV辅助计算**成为热点（论文1、4、7），研究聚焦于：

- UAV轨迹优化与干扰规避（论文1）
- UAV与车辆协同计算与能效优化（论文7）
- 多目标优化框架（MODE-DRL）提升系统整体性能（论文4）

并且，在论文2中**多跳卸载与车车协同（V2V）**被用于应对基站覆盖不足与链路中断。由此可见，**空地协同（UAV-VEC）与车车中继协同**正在成为IoV-MEC系统的新型体系结构。

## (3) 深度强化学习（DRL）在动态优化中已广泛应用

**DRL**已成为主流工具，用于处理IoV环境的高动态性与高维状态空间：

- 单智能体：SR-CL（论文3）
- 多智能体：MA-TD3（论文1）、Fed-MADDPG（论文8）、HMADRL（论文5）

## (4) 隐私保护与激励机制是新兴主题

**隐私保护与可信激励**是近年来的新兴主题：

- 联邦学习与隐私保护（论文5、8）
- 匿名认证与可撤销访问控制（RFIP-VEC，论文9）
- 奖励驱动的拍卖机制激励车辆协作（论文2）
- 引入博弈论（进化博弈、潜在博弈）建模车辆间合作与竞争关系（论文2、9）

由此可见，结合联邦学习、区块链、安全签名机制的**可信VEC**系统成为了研究重点。